

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA

ESPECIALIDAD DE INGENIERÍA INFORMÁTICA



**Desarrollo de una Arquitectura MLOps para la Validación Continua de
Equidad (*Fairness*) como Prueba de Calidad (QA) en Modelos de Scoring
Crediticio**

Tesis para obtener el título profesional de Ingeniero Informático

AUTOR:

Sergio Alonso Chumbimuni Bustamante

ASESOR:

Luis Vives Garnique

Lima, Agosto, 2026

Índice

Capítulo 1. Generalidades.....	4
1.1 Problemática.....	4
1.1.1 Descripción.....	4
1.1.2 Árbol de problemas.....	6
1.1.3 Problema seleccionado.....	8
1.2 Objetivos.....	8
1.2.1 Objetivo General.....	8
1.2.2 Objetivos específicos.....	8
1.2.3 Resultados esperados.....	9
1.2.4 Mapeo de objetivos, resultados y verificación.....	10
1.3 Métodos y Procedimientos.....	14
1.3.1 Herramientas.....	16
1.3.2 Metodologías y Procedimientos.....	19
Capítulo 2. Marco Conceptual, Teórico y Legal.....	21
2.1 Marco Conceptual.....	21
2.1.1 El Scoring Crediticio en la Gestión del Riesgo de Crédito.....	21
2.1.2 El sesgo algorítmico y la equidad en el Scoring Crediticio.....	23
2.1.3 Métricas matemáticas de Equidad de Grupo.....	24
2.1.4 Métricas matemáticas de Equidad Individual y Multiplicidad.....	25
2.1.5 Degradación del sistema: Drift de Datos, de Concepto y de Sesgo.....	27
2.1.6 El dilema de Precisión frente a Equidad (Accuracy-Fairness Trade-off).....	27
2.2 Marco Teórico.....	28
2.2.1 El paradigma MLOps y la automatización CI/CD.....	28
2.2.2 Aseguramiento de Calidad proactivo: Shift-Left Testing y Contratos de Equidad.	29
2.2.3 Trazabilidad semántica mediante Grafos de Conocimiento (RDF/OWL).....	30
2.3 Marco Legal.....	31
2.3.1 Ley de IA de la Unión Europea (EU AI Act - Reglamento UE 2024/1689).....	31
2.3.2 Normativa de Equidad en Finanzas Globales (ECOIA de Estados Unidos).....	32
2.3.3 Estándar Internacional de Gestión de IA (ISO/IEC 42001).....	33
Capítulo 3. Estado del Arte.....	34
3.1 Introducción.....	34
3.2 Objetivos de revisión.....	35
3.3 Preguntas de revisión.....	37
3.4 Protocolo de búsqueda.....	38
3.4.1 Motores de búsqueda.....	39
3.4.2 Cadenas de búsqueda a usar.....	39
3.5 Criterios de inclusión y exclusión.....	41
3.6 Formulario de extracción de datos.....	45
3.6 Resultados de revisión.....	48
3.6.1 Respuesta a Pregunta de Revisión 1.....	48
3.6.2 Respuesta a Pregunta de Revisión 2.....	49

3.6.3 Respuesta a Pregunta de Revisión 3.....	50
3.6.4 Respuesta a Pregunta de Revisión 4.....	51
3.7 Conclusiones del Estado del Arte.....	52
Capítulo 4: Diseño de la propuesta de solución.....	54
4.1 Introducción.....	54
4.2 Esquema arquitectónico detallado (Modelo C4) y flujos CI/CD.....	55
4.2.1. Descripción del resultado alcanzado.....	55
4.2.2 Metodología de logro y reproducibilidad.....	61
4.2.3. Verificación de existencia.....	62
4.2.4 Mediciones y validación del indicador.....	62
4.3 Especificación de diseño de los componentes modulares de validación de equidad.....	64
4.3.1. Descripción del resultado alcanzado.....	64
4.3.2. Metodología de logro y reproducibilidad.....	65
4.3.3. Verificación de existencia.....	66
4.3.4. Mediciones y validación del indicador.....	67
4.4. Modelo conceptual de trazabilidad y gobernanza semántica.....	70
4.3.1. Descripción del resultado alcanzado.....	70
4.5. Discusión.....	70
4.5.1. Síntesis de los resultados principales.....	70
4.5.2. Interpretación del significado de los resultados.....	71
4.5.3. Contextualización con la revisión de la literatura.....	71
4.5.4. Generalización de los resultados.....	72
4.5.5. Limitaciones de los resultados.....	73
Referencias bibliográficas.....	74
Anexo A: Formulario de Extracción	
Formulario de Extracción.....	79
Anexo B: Plan de Proyecto.....	80

Capítulo 1. Generalidades

1.1 Problemática

1.1.1 Descripción

En el ecosistema financiero internacional, las instituciones de tecnología financiera (*Fintech*) y la banca global emplean de manera generalizada algoritmos de aprendizaje automático (*Machine Learning* - ML) para automatizar el otorgamiento de créditos y evaluar la solvencia de los solicitantes (Byanjankar et al., 2015; IJAIDSML, 2020). Si bien este enfoque reduce los costos operativos y optimiza los tiempos de respuesta, los modelos predictivos absorben y perpetúan de manera silenciosa los sesgos sociales e históricos presentes en los datos de entrenamiento (Ghai et al., 2022; IBM, s.f.). El gran riesgo es la generación de exclusión financiera y discriminación injustificada contra subgrupos vulnerables al calificar su comportamiento crediticio.

Evidencia empírica reciente en la era Fintech demuestra que, aunque el uso de algoritmos de lending automatizados puede reducir la discriminación en aproximadamente un 40% en comparación con los prestamistas humanos tradicionales al eliminar prejuicios cara a cara, el sesgo algorítmico y la discriminación por *proxy* persisten de forma sistemática (Bartlett et al., 2022).

Un problema crítico en el desarrollo de estos sistemas es que la discriminación no surge únicamente del conjunto de datos inicial, sino que puede inyectarse y amplificarse de manera silenciosa durante las etapas intermedias de preparación de datos, como la limpieza, normalización o imputación de valores faltantes (Biswas & Rajan, 2021). En la práctica operativa actual, los análisis de equidad se realizan únicamente al final del ciclo de desarrollo sobre el modelo ya entrenado, tratándolo como una "caja negra" (Nguyen et al., 2025). Esta falta de verificación modular impide a los desarrolladores y científicos de datos identificar en qué punto específico de la canalización de software se originó la

desviación, obligando a los equipos a realizar costosos, lentos y propensos a error procesos de depuración manual.

Asimismo, la confiabilidad de los clasificadores de riesgo disminuye drásticamente tras su despliegue debido a que el comportamiento demográfico y macroeconómico del mercado real cambia constantemente en comparación con el entorno estático con el que fueron entrenados (AWS, 2022). Sin una supervisión constante, estas variaciones provocan que un algoritmo que se consideraba justo y preciso durante su desarrollo comience a generar resultados discriminatorios inadvertidos al operar con datos en vivo (Avuthu, 2021; IBM, s.f.).

Esta necesidad técnica ha cobrado un carácter de urgencia legal a nivel internacional. El **Reglamento (UE) 2024/1689 (Ley de IA de la Unión Europea - EU AI Act)** clasifica de manera estricta a los sistemas de IA utilizados para evaluar la solvencia o la calificación crediticia de personas naturales como sistemas de riesgo alto (Anexo III, punto 5.b) (Reglamento IA UE, 2024). Asimismo, en los Estados Unidos, regulaciones como la **Equal Credit Opportunity Act** (ECOA) prohíben de forma contundente la discriminación crediticia basándose en atributos protegidos como el género, la raza o la edad (ECOA, 1974). Estos marcos internacionales imponen a los desarrolladores e implementadores obligaciones imperativas de control de calidad, mitigación preventiva de sesgos y el mantenimiento de un registro de trazabilidad automático de las fuentes de datos y la lógica de los algoritmos para facilitar auditorías externas (Reglamento IA UE, 2024).

La ausencia de metodologías integradas que automaticen la verificación de equidad etapa por etapa en el ciclo de vida del software y que generen documentación auditable sobre las decisiones del modelo impide que las Fintech operen de forma competitiva a escala global mientras cumplen simultáneamente con los estándares éticos y las exigencias de fiscalización de los reguladores financieros más estrictos del mundo.

1.1.2 Árbol de problemas

En la **Figura 1** se presenta el árbol de problemas de la presente investigación, en el cual se representa de manera esquemática la relación entre las causas que originan la problemática identificada en los flujos de calificación crediticia automática.




Figura 1: Árbol de problemas

- **Canal de Causalidad 1 (Pre-desarrollo - Análisis de la Literatura):** La carencia de arquitecturas MLOps que evalúen los sesgos de la canalización de Machine Learning de forma inherente conduce a la toma de decisiones arbitrarias e injustificables para los solicitantes de crédito, limitando la confianza en la adopción de estos sistemas . Al no contar con flujos de trabajo automatizados que incorporen consideraciones éticas desde su raíz, la selección de modelos se reduce a criterios de exactitud, ignorando asimetrías de impacto en atributos protegidos. Este canal justifica el Objetivo Específico O1 (Analizar), orientado a identificar las brechas y capacidades de gobernanza ética en las arquitecturas MLOps existentes.
- **Canal de Causalidad 2 (Diseño Arquitectónico Modular - Etapas del Pipeline):** La falta de una propuesta arquitectónica MLOps integrada que evalúe de forma continua y modular los sesgos introducidos en las diferentes etapas del pipeline de Machine Learning —incluyendo la ingesta, el preprocesamiento, el entrenamiento y el monitoreo— genera una degradación silenciosa de la equidad del software y elevados costos operativos para diagnosticar y localizar la causa raíz de la discriminación en el código. Al tratarse el pipeline como un bloque monolítico, los sesgos por proxy se propagan sin control en las fases intermedias de

transformación. Este canal justifica el Objetivo Específico O2 (Diseñar), orientado a establecer un esquema arquitectónico modular que localice y controle preventivamente el sesgo etapa por etapa.

- **Canal de Causalidad 3 (Flujo CI/CD - Implementación del Prototipo):** La ausencia de soluciones MLOps implementadas que articulen herramientas y metodologías orientadas a la evaluación continua de sesgos con la trazabilidad y la documentación auditable de las decisiones algorítmicas resulta en la incapacidad de la Fintech para cumplir con auditorías éticas, de gobernanza y regulatorias internacionales severas (como el EU AI Act o la ECOA estadounidense) debido a la opacidad y la falta de evidencias técnicas estructuradas. Al no integrar el control ético de calidad con repositorios de metadatos, se mantiene una dependencia de procesos manuales lentos e inconsistentes. Este canal justifica el Objetivo Específico O3 (Desarrollar), cuyo propósito es instrumentar un prototipo automatizado que integre controles de equidad con una capa semántica para la trazabilidad.
- **Canal de Causalidad 4 (Monitoreo - Evaluación Comparativa):** La carencia en la evaluación comparativa del desempeño de arquitecturas MLOps orientadas a la mitigación y evaluación continua de sesgos ante escenarios dinámicos del mundo real origina el despliegue involuntario y la persistencia en producción de modelos de scoring crediticio discriminatorios que perpetúan sesgos históricos y daños sistémicos de exclusión financiera contra subgrupos vulnerables. Al no validar experimentalmente la resiliencia del sistema frente a perturbaciones o derivas de datos, el pipeline permanece vulnerable. Este canal justifica el Objetivo Específico O4 (Evaluar), orientado a contrastar empíricamente la efectividad de la arquitectura bajo pruebas de estrés de forma sistémica.

1.1.3 Problema seleccionado

El problema central seleccionado consiste en las **deficiencias metodológicas y de infraestructura para la validación, el monitoreo continuo y la documentación auditable de la equidad algorítmica dentro de los pipelines MLOps de scoring crediticio a nivel global**. Este problema radica en que los flujos de trabajo actuales de aprendizaje automático separan el despliegue técnico del aseguramiento de la calidad ética (Dhaenens, 2024). Al no evaluar la equidad de forma continua e integrada en el ciclo de vida del software, las

canalizaciones corren el riesgo de sufrir degradaciones silenciosas donde las transformaciones de datos intermedias o los cambios del entorno en producción introducen discriminación contra subgrupos vulnerables sin generar alertas técnicas (Biswas & Rajan, 2021).

1.2 Objetivos

1.2.1 Objetivo General

Implementar una arquitectura MLOps de Nivel 2 orientada a la validación continua de equidad (*fairness*) como prueba de aseguramiento de calidad (QA) automatizada y auditable para modelos predictivos supervisados de scoring crediticio, demostrando su viabilidad técnica, eficacia en la mitigación de riesgos éticos y adaptabilidad operativa en el contexto global de desarrollo de software confiable.

1.2.2 Objetivos específicos

- **O1:** Analizar el estado del arte y las brechas tecnológicas en las arquitecturas MLOps existentes que abordan el aseguramiento de equidad e integración de controles continuos en el desarrollo de software.
- **O2:** Diseñar el esquema de la arquitectura MLOps local que integre compuertas de calidad (*QA Gates*) modulares y un modelo semántico para garantizar la trazabilidad ética en todas las etapas del pipeline de scoring crediticio.
- **O3:** Implementar el prototipo funcional de la arquitectura local integrando herramientas de automatización CI/CD, contratos de validación de equidad en tiempo de compilación y almacenamiento semántico en un grafo de conocimiento.
- **O4:** Evaluar la efectividad de la arquitectura MLOps propuesta en un entorno de simulación local, utilizando el dataset de una Fintech real y aplicando pruebas de estrés mediante la inyección sintética de sesgos y derivas de datos.

1.2.3 Resultados esperados

A continuación, se detallan los 3 resultados esperados correspondientes a cada objetivo específico:

Para el Objetivo Específico 1 (Análisis de Arquitecturas *MLOps* existentes):

- **R.E.1.1:** Un documento de revisión de la literatura que recopile y filtre las arquitecturas y marcos de trabajo *MLOps* actuales orientados a la validación de equidad en modelos predictivos.
- **R.E.1.2:** Una matriz de análisis comparativo que evalúe las arquitecturas existentes en términos de sus capacidades de automatización, integración continua, monitoreo y trazabilidad documental.
- **R.E.1.3:** Un informe de brechas tecnológicas que identifique las limitaciones operativas de las soluciones actuales para fundamentar y justificar el diseño de la nueva propuesta arquitectónica.

Para el Objetivo Específico 2 (Diseño de la arquitectura *MLOps* proactiva):

- **R.E.2.1:** Un esquema arquitectónico detallado (C4 hasta el nivel 3) que defina la solución bajo un patrón de *Pipeline* por Etapas (Integración y Entrega Continua) y una capa superior Orientada al Conocimiento para la trazabilidad, estableciendo la ubicación exacta de las compuertas de calidad a lo largo de la canalización.
- **R.E.2.2:** Una especificación de diseño de los componentes modulares de validación de equidad, detallando las reglas o puntos de control que se evaluarán de forma preventiva en las fases críticas donde se genera el sesgo.
- **R.E.2.3:** Un modelo conceptual de trazabilidad diseñado para capturar y estructurar los metadatos del sistema, permitiendo registrar el linaje de los datos y las métricas de equidad para su posterior auditoría.

Para el Objetivo Específico 3 (Implementación de la arquitectura *MLOps* propuesta):

- **R.E.3.1:** Un entorno de integración continua automatizado y configurado que incluya la instrumentación necesaria para la inspección proactiva de los componentes del *pipeline* de aprendizaje automático.
- **R.E.3.2:** Los módulos de validación de equidad programados e integrados en la canalización, utilizando aserciones evaluadas en tiempo de compilación. Estos módulos tendrán la capacidad técnica de interrumpir automáticamente el flujo del orquestador y abortar el despliegue del modelo si un componente viola los contratos de equidad establecidos.
- **R.E.3.3:** Un servicio de monitoreo y registro implementado, capaz de recopilar información de las predicciones y del ciclo de vida del modelo

para detectar desviaciones en el tiempo y facilitar la exportación de reportes.

Para el Objetivo Específico 4 (Evaluación de la efectividad frente a enfoques tradicionales):

- **R.E.4.1:** Escenarios de prueba de estrés mediante la inyección sintética de sesgos y derivas en el conjunto de datos de scoring crediticio.
- **R.E.4.2:** Resultados analíticos comparativos de rendimiento técnico (tasa de detección, tiempo de respuesta y precisión de localización) frente a enfoques tradicionales.
- **R.E.4.3:** Informe final con consultas semánticas SPARQL y el reporte de cumplimiento PDF autogenerado desde el Grafo de Trazabilidad.

1.2.4 Mapeo de objetivos, resultados y verificación

A continuación, se presenta la matriz de trazabilidad que vincula cada objetivo específico con sus respectivos resultados esperados, estableciendo los medios de verificación tangibles y los indicadores objetivamente verificables que certificarán el cumplimiento de las metas del proyecto a lo largo de su ciclo de desarrollo.

Resultado Esperado	Medio de verificación	Indicador objetivamente verificable
R.E.1.1: Un documento de revisión de la literatura que recopile y filtre las arquitecturas y marcos de trabajo <i>MLOps</i> actuales orientados a la validación de equidad en modelos predictivos.	Capítulo 3 del documento de tesis (Estado del Arte).	Revisión sistemática completada utilizando el diagrama de flujo PRISMA con al menos 20 estudios primarios seleccionados.
R.E.1.2: Una matriz de análisis comparativo que	Formulario de extracción (incluida en	Matriz completada que evalúa el 100% de los

evalúe las arquitecturas existentes en términos de sus capacidades de automatización, integración continua, monitoreo y trazabilidad documental.	los Anexos).	estudios seleccionados bajo los criterios metodológicos y tecnológicos de <i>MLOps</i>
R.E.1.3: Un informe de brechas tecnológicas que identifique las limitaciones operativas de las soluciones actuales para fundamentar y justificar el diseño de la nueva propuesta.	Sección de "Conclusiones del Estado del Arte" en el informe.	Identificación y justificación documentada de al menos tres (3) limitaciones operativas o arquitectónicas en los enfoques actuales.

Tabla 1. Resultados esperados, medios de verificación e indicadores objetivamente verificables para el objetivo específico 1.

Resultado Esperado	Medio de verificación	Indicador objetivamente verificable
R.E.2.1: Un esquema arquitectónico detallado que defina las distintas capas del ciclo de vida del modelo y establezca la ubicación exacta de las compuertas de calidad.	Diagramas de contenedores y componentes basados en estándares de modelado de software.	Presentación de diagramas que identifiquen explícitamente el flujo de integración continua, la capa de persistencia semántica y la ubicación estratégica de los puntos de validación.
R.E.2.2: Especificación técnica y formulación de reglas, umbrales y aserciones de equidad en las diferentes etapas de la canalización de software.	Documento de especificación de diseño técnico.	Formulación matemática de las restricciones y umbrales tolerables de equidad para la ingesta de datos crudos, la transformación de características y el

		modelo predictivo final.
R.E.2.3: Modelo conceptual de metadatos de trazabilidad diseñado para estructurar el linaje y las métricas de sesgo.	Esquema del modelo semántico o vocabulario de gobernanza del software.	Modelo conceptual estructurado que interconecte las entidades de datos, modelo, métricas de sesgo y resultados de ejecución.

Tabla 2. Resultados esperados, medios de verificación e indicadores objetivamente verificables para el objetivo específico 2.

Resultado Esperado	Medio de verificación	Indicador objetivamente verificable
R.E.3.1: Un entorno de integración continua (<i>CI</i>) automatizado y configurado que incluya la instrumentación necesaria para la inspección proactiva.	Repositorio de código fuente con pipelines de <i>CI</i> configurados.	Ejecución exitosa y automatizada del pipeline base en un servidor de integración sin errores de compilación o empaquetado.
R.E.3.2: Módulos de validación y control de equidad integrados en la canalización con capacidad de interrupción.	Código fuente y bitácora de ejecución de las compuertas de calidad.	Interrupción automatizada e inmediata de la canalización (salida con código de error) cuando un componente viole los umbrales de equidad establecidos.
R.E.3.3: Servicio de monitoreo continuo de deriva y registro de metadatos de experimentos implementado.	Logs de auditoría, bitácoras de ejecución y tableros de visualización de métricas de software.	Registro automático y persistente de los metadatos de entrenamiento, predicciones en vivo y alertas de deriva ética generados en el ciclo de vida.

Tabla 3. Resultados esperados, medios de verificación e indicadores objetivamente verificables para el objetivo específico 3.

Resultado Esperado	Medio de verificación	Indicador objetivamente verificable
R.E.4.1: Escenarios de validación experimental mediante la inyección sistemática de sesgos y anomalías de datos en scoring crediticio.	Scripts de inyección de distorsiones y conjuntos de datos de prueba.	Simulación documentada de al menos dos (2) escenarios de prueba que apliquen perturbaciones estructurales en las variables y deriven en drift ético.
R.E.4.2: Resultados cuantitativos comparativos de desempeño de calidad y eficiencia técnica frente a enfoques tradicionales.	Tablas y gráficos comparativos de desempeño técnico.	Demostración empírica de la mejora en velocidad de interrupción, tasa de detección y precisión de localización del sesgo frente al Nivel 0 de MLOps.
R.E.4.3: Informe final de evaluación y reporte de cumplimiento semántico automatizado.	Informe técnico de auditoría.	Consulta y recuperación exitosa de metadatos en el grafo de conocimiento para generar el informe automatizado que certifique el cumplimiento normativo.

Tabla 4. Resultados esperados, medios de verificación e indicadores objetivamente verificables para el objetivo específico 4.

1.3 Métodos y Procedimientos

En esta sección se describen los métodos, herramientas y procedimientos que se emplearán para alcanzar los resultados esperados de esta investigación. La elección de cada componente tecnológico y metodológico se fundamenta en las

prácticas modernas de la Ingeniería de Software para Inteligencia Artificial (AIMS) y la literatura reciente sobre MLOps y gobernanza algorítmica (Kazmierczak et al., 2024; Russo et al., 2024).

Resultado Esperado	Herramientas	Métodos y procedimientos
R.E.1.1 a R.E.1.3 (Revisión de literatura, matriz y brechas tecnológicas)	- Motores de Búsqueda (<i>Scopus, IEEE Xplore, Google Scholar</i>) - Zotero - Google Sheets	- Revisión Sistemática de la Literatura basada en la metodología PICOC y el diagrama de flujo PRISMA. - Análisis comparativo de arquitecturas.
R.E.2.1 a R.E.2.3 (Esquema arquitectónico, diseño de <i>QA Gates</i> y modelo de trazabilidad semántica)	- LucidChart - Especificaciones RDF/OWL	- Modelado arquitectónico de software utilizando el estándar del Modelo C4). - Diseño lógico-conceptual de Contratos de Equidad modulares (precondiciones y postcondiciones) para el aislamiento del sesgo composicional. - Modelado conceptual de la Ontología OWL de Fairness (Noy & McGuinness) para la estructuración lógica de los metadatos y linaje de datos de crédito.
R.E.3.1 a R.E.3.3 (Entorno CI, validación de equidad automatizada y monitoreo)	- Python (pandas y scikit-learn) - Pytest - GitHub Actions (CI/CD)	- Implementación de canalizaciones MLOps locales de Nivel 2 orientadas a la entrega continua local (CI/CD/CT) sin

	- MLflow - AIF360 / Fairlearn - Pandera - DVC - Evidently AI - SHAP	dependencias de la nube. - Programación de aserciones de software y compuertas de calidad preventivas (<i>QA Gates</i>) acopladas de forma declarativa (YAML) al código fuente con capacidad de interrupción en caliente (exit 1 en Pytest). - Instrumentación de telemetría de inferencia, explicabilidad local por deudor (SHAP) y monitoreo continuo de derivas (<i>bias drift</i>) en producción.
R.E.4.1 a R.E.4.3 (Escenarios de prueba, resultados comparativos e informe final)	- Pytest - GraphDB - InterpretME - RDFLib - SPARQL	- Pruebas de estrés inyectando sesgos sistemáticos en los datos. - Validación experimental y evaluación de métricas de equidad. - Redacción del informe de auditoría.

Tabla 5. Mapeo de resultados esperados con herramientas, métodos y procedimientos.

1.3.1 Herramientas

A continuación, se describen y justifican las herramientas, bibliotecas y plataformas seleccionadas para la investigación, en concordancia con los

requerimientos técnicos de la arquitectura MLOps, el aseguramiento de la calidad y la gobernanza algorítmica:

- **Motores de Búsqueda (Scopus, IEEE Xplore, Google Scholar):** Se utilizaron como las principales bases de datos para la ejecución de la revisión sistemática de la literatura. Scopus e IEEE Xplore representan los repositorios de mayor impacto en los campos de ingeniería de software y ciencias de la computación, indispensables para la recuperación de estándares técnicos sobre *MLOps*. Por su parte, Google Scholar sirvió como motor complementario para capturar literatura gris y estudios recientes de alto valor empírico.
- **Zotero:** Gestor bibliográfico de software libre que se empleó durante la fase de recopilación del estado del arte. Su uso permitió almacenar los metadatos de los estudios primarios, organizar las referencias bajo el estándar APA y automatizar la eliminación de documentos duplicados durante la fase de cribado del diagrama PRISMA.
- **Google Sheets:** Herramienta de hojas de cálculo basada en la nube que se utilizó para el diseño y la gestión del formulario de extracción de datos. Facilitó la consolidación del formulario de extracción (Anexo A) de las arquitecturas *MLOps*, permitiendo organizar las brechas, los enfoques y las métricas de manera colaborativa y estructurada.
- **Lucidchart:** Plataforma de diagramación basada en la web que se empleará para el diseño conceptual y formal de la arquitectura de software. Su uso es esencial para elaborar los esquemas de flujo y los diagramas de componentes, permitiendo comunicar visualmente la ubicación estratégica de las compuertas de calidad dentro del ciclo de vida del *Machine Learning*.
- **Especificaciones RDF (Resource Description Framework):** Estándar del World Wide Web Consortium (W3C) para el modelado semántico de la información. En este proyecto, RDF proporcionará el marco estructural para diseñar el modelo conceptual del Grafo de Conocimiento (Capa de Trazabilidad), permitiendo interconectar el linaje de los datos, los parámetros del modelo y las métricas de sesgo en un formato legible tanto para máquinas como para auditores humanos.
- **Python (pandas y scikit-learn):** Python será el lenguaje de programación base debido a su predominio y soporte en la ingeniería de IA. Se utilizará la biblioteca pandas para la manipulación y el preprocesamiento de los conjuntos de datos tabulares, mientras que

scikit-learn se empleará para la construcción de los *pipelines* de aprendizaje automático y la implementación de los estimadores y transformadores de datos.

- **Pandera:** Biblioteca de Python para la validación declarativa de datos tabulares basada en esquemas. Permite definir contratos de datos como clases o decoradores que especifican los tipos, rangos, restricciones y reglas personalizadas que debe cumplir un *DataFrame* de Pandas, y lanza excepciones tipadas cuando alguna columna o valor viola el esquema defin. En el contexto de esta arquitectura, se usa en la Zona 1 como motor de las aserciones del Contrato 1A para verificar integridad estructural del dataset antes de que entre al *pipeline* de preprocesamiento.
- **GitHub Actions (CI/CD):** Plataforma de automatización que actuará como el motor principal para habilitar las operaciones de Integración y Entrega Continua (CI/CD). Permitirá orquestar los flujos de trabajo para ejecutar de manera automática el *pipeline de Machine Learning* y las compuertas de calidad cada vez que se detecten cambios en el código fuente o en los datos del repositorio.
- **DVC (Data Version Control):** Herramienta de código abierto diseñada para el versionado y la gestión de datos y modelos en proyectos de aprendizaje automático, funcionando como una extensión de Git para artefactos de gran tamaño. En la arquitectura, se integrará en la Zona 1 como el componente central del *Feature Store*, permitiendo versionar cada lote de datos procesado mediante un identificador hash reproducible. Esto garantiza que cada ejecución del pipeline pueda ser vinculada a una versión exacta del *dataset* de entrada, proporcionando el linaje de datos necesario para alimentar el Grafo de Conocimiento de la Zona 4 y cumplir con los requisitos de trazabilidad exigidos por el *AI Act*.
- **Evidently AI:** Biblioteca de código abierto orientada al monitoreo y la evaluación de modelos de aprendizaje automático en entornos de producción. En la arquitectura, se empleará en la Zona 3 como el motor de detección de deriva, permitiendo comparar continuamente la distribución de los datos de producción con los datos de entrenamiento para identificar anomalías estructurales (*data drift*) y degradaciones en el comportamiento predictivo (*concept drift*). Adicionalmente, su capacidad para generar reportes de auditoría ética en tiempo real sobre atributos protegidos lo convierte en el componente responsable de detectar la deriva del sesgo (*bias drift*) y activar el ciclo de reentrenamiento continuo

cuando la calidad ética del modelo se degrada por debajo del umbral aceptable.

- **MLflow:** Plataforma de código abierto estándar en la industria para la gestión del ciclo de vida del aprendizaje automático. En la arquitectura, se integrará para automatizar el registro de experimentos, el versionado de artefactos y la recolección de métricas de rendimiento, garantizando la reproducibilidad y facilitando el monitoreo entre las distintas iteraciones de los modelos.
- **AIF360 / Fairlearn:** Conjuntos de herramientas de código abierto desarrollados para la evaluación y mitigación de sesgos algorítmicos. Estas bibliotecas proveerán los algoritmos matemáticos necesarios para instrumentar las compuertas de calidad, calculando métricas como la Paridad Demográfica o la Igualdad de Oportunidades durante la ejecución de las pruebas preventivas.
- **InterpretME:** Herramienta de código abierto que integra métodos de *Machine Learning* con Grafos de Conocimiento. Se incrustará en el pipeline de desarrollo para rastrear automáticamente la ejecución del modelo y semantizar sus metadatos (características de entrada, hiperparámetros y métricas de equidad), generando artefactos de documentación auditable validados mediante restricciones *SHACL*.
- **RDFLib:** Biblioteca nativa de Python para la creación, manipulación y serialización de datos en formato RDF (*Resource Description Framework*). En la arquitectura, actúa como el puente de integración entre el pipeline de *MLOps* y el Grafo de Conocimiento de la Zona 4, permitiendo transformar los metadatos extraídos por InterpretME —hiperparámetros, métricas de equidad y resultados de los Contratos de Equidad— en triples semánticos con estructura sujeto-predicado-objeto, conformes a la ontología OWL de *fairness* definida en el sistema. Los artefactos RDF generados son posteriormente cargados en GraphDB para su persistencia y consulta mediante SPARQL.
- **SHAP (SHapley Additive exPlanations):** Biblioteca de Python basada en la teoría de valores de Shapley de la teoría de juegos cooperativos, que permite calcular la contribución individual de cada característica de entrada a la predicción de un modelo de aprendizaje automático. En la arquitectura, se utilizará en la Zona 2 como el componente de explicabilidad del *pipeline* de entrenamiento, generando valores de importancia de features tanto a nivel global del modelo como a nivel de

instancia individual. Estos valores son consumidos por InterpretME para su semantización en el Grafo de Conocimiento y constituyen la evidencia técnica requerida por el *AI Act* para justificar decisiones automatizadas ante individuos afectados y autoridades regulatorias.

- **Pytest:** Framework de pruebas unitarias para Python. Se empleará para programar la lógica de los "Contratos de Equidad" y las aserciones de validación dentro del pipeline. Al integrarse con GitHub Actions, Pytest será el responsable de evaluar las condiciones de equidad en tiempo de compilación e interrumpir (abortar) el despliegue del modelo si los sesgos superan los umbrales tolerados.
- **GraphDB:** Sistema de gestión de bases de datos orientadas a grafos. Actuará como la infraestructura de persistencia para el Grafo de Conocimiento generado por InterpretME. Su soporte nativo para el lenguaje de consulta SPARQL permitirá a los analistas y auditores explorar la trazabilidad de la arquitectura *MLOps* de manera eficiente y recuperar la documentación semántica del sistema.

1.3.2 Metodologías y Procedimientos

Para desarrollar, implementar y evaluar la arquitectura MLOps propuesta, se emplea una metodología de **investigación aplicada y diseño de software**, estructurada de manera secuencial a lo largo de las siguientes cinco (5) fases operativas:

- **Fase 1: Revisión Sistemática de la Literatura (O1):** El Estado del Arte de esta investigación se construirá aplicando de manera rigurosa la estrategia de búsqueda PICOC y el diagrama de flujo PRISMA, garantizando un proceso estructurado, transparente y reproducible para la selección de la literatura primaria. Esta fase permitirá identificar y fundamentar las brechas operativas en la automatización de controles de equidad dentro de la industria de tecnología financiera (*Fintech*).
- **Fase 2: Diseño Arquitectónico y Formulación de Contratos (O2):** Consiste en el diseño formal de la solución. Primero, se modelará la arquitectura modular en cuatro Zonas operativas locales utilizando la metodología del Modelo C4 (Contexto, Contenedores y Componentes). Segundo, se aplicará el paradigma de Diseño por Contrato (DbC) para formular de forma matemática precondiciones y postcondiciones duras (Contratos C1, C2 y C3 en archivos YAML) correspondientes a las tres

compuertas (*QA Gates*) (Nguyen, 20 Nguyen et al., 2025). Tercero, se diseñará el modelo de datos conceptual de la Ontología OWL de Fairness aplicando la metodología de ingeniería ontológica de Noy y McGuinness para conectar lógicamente entidades de datos, hiperparámetros, métricas éticas y atribuciones SHAP (Russo et al., 2024).

- **Fase 3: Desarrollo e Implementación del Prototipo MLOps (O3):** Involucra la materialización técnica del diseño abstracto. Se construirá localmente la canalización automatizada mediante Python, entrenando clasificadores supervisados base (como Regresión Logística e interactuando con Random Forests). Se integrará DVC para el Feature Store, MLflow para el tracking y Pytest para instrumentar la interrupción automática en caliente ante fallos en los contratos.
- **Fase 4: Trazabilidad Semántica e Integración Neurosimbólica (O3 - Continuación):** Consiste en programar el flujo de recolección de metadatos mediante InterpretME y RDFLib, transformando automáticamente las ejecuciones de compilación de Pytest, métricas del modelo y valores de importancia SHAP en triples RDF. Estos triples se persistirán en la base local GraphDB, garantizando el linaje de datos de extremo a extremo (Russo & Vidal, 2025).
- **Fase 5: Validación Experimental mediante Pruebas de Estrés Financiero (O4):** Representa la fase de validación científica de software. Se simularán escenarios controlados de inestabilidad demográfica y de sesgo por proxy inyectando distorsiones en los transformadores en un entorno de staging. Se medirá cuantitativamente la tasa de detección del sistema, el tiempo de respuesta del bloqueo preventivo y el grado de mitigación de la paridad estadística (SPD) e impacto dispar (DI) en el modelo entregado (Zhu et al., 2025). Se verificará que el Auditor de software pueda generar reportes PDF de cumplimiento automáticos ejecutando consultas SPARQL en GraphDB.

Capítulo 2. Marco Conceptual, Teórico y Legal

En este capítulo se desarrollan las bases conceptuales, teóricas y normativas que fundamentan científicamente la presente investigación. Para evitar una presentación aislada de términos, la estructura sigue un hilo conductor narrativo: el **Marco Conceptual** caracteriza la naturaleza matemática y estadística de la equidad y del sesgo; el **Marco Teórico** describe las metodologías y herramientas de ingeniería de software necesarias para automatizar y

documentar de manera proactiva dicho aseguramiento de calidad; y el **Marco Legal** detalla la justificación regulatoria global que impone la obligatoriedad de implementar estos controles técnicos en sistemas de alto riesgo.

2.1 Marco Conceptual

Esta sección aborda de manera rigurosa la naturaleza empírica y formal de los sesgos algorítmicos, la formulación matemática de las métricas de equidad que serán evaluadas programáticamente, y los fenómenos de degradación de modelos en producción.

2.1.1 El Scoring Crediticio en la Gestión del Riesgo de Crédito

En el sector de la tecnología financiera (*Fintech*) y la banca global, el Scoring Crediticio representa el núcleo analítico y el pilar fundamental para la cuantificación y gestión de los riesgos financieros (MathWorks, s.f.; Stoyanovich et al., 2022). Este proceso se define formalmente como un enfoque metodológico cuantitativo diseñado para estimar la probabilidad de que un solicitante o prestatario incumpla con sus obligaciones contractuales de pago (es decir, caiga en *default*) (MathWorks, s.f.; BCBS, 2025). De acuerdo con las directrices multilaterales emitidas por el Comité de Basilea sobre Supervisión Bancaria (Basel Committee on Banking Supervision), las instituciones deben mantener entornos sólidos de otorgamiento y monitoreo continuo del crédito, asegurando una debida gobernanza sobre los procesos predictivos utilizados para la evaluación de deudores (BCBS, 2025).

De acuerdo con los estándares regulatorios internacionales de capital y provisiones, tales como Basilea III y las Normas Internacionales de Información Financiera (IFRS 9 / CECL), la medición de las pérdidas proyectadas de una cartera de crédito se fundamenta en el cálculo de la Pérdida Esperada (Expected Credit Loss - ECL) (MathWorks, s.f.; BCBS, 2025). Este cálculo se rige de manera uniforme bajo la siguiente formulación matemática (MathWorks, s.f.; BCBS, 2025): $ECL = PD \times LGD \times EAD$ Donde:

- **Probabilidad de Default (Probability of Default - PD):** Es la medida probabilística que cuantifica la probabilidad de que un deudor incumpla con sus pagos en un horizonte temporal determinado (típicamente 12 meses o a lo largo del ciclo de vida útil del préstamo) (BCBS, 2025; MathWorks, s.f.).

- **Pérdida en Caso de Default (Loss Given Default - LGD):** Estima el porcentaje de la exposición que verdaderamente se perderá en caso de que ocurra el incumplimiento, neto de los procesos de recuperación o de ejecución de garantías colaterales (BCBS, 2025; MathWorks, s.f.).
- **Exposición al Momento del Default (Exposure at Default - EAD):** Representa el monto total de deuda pendiente que el cliente tiene con la entidad financiera al instante exacto del incumplimiento (BCBS, 2025; MathWorks, s.f.).

En esta tesis, el scoring crediticio se modela formalmente como una tarea de clasificación binaria supervisada (MathWorks, s.f.). Sea X un vector multidimensional que representa las características financieras, transaccionales, de comportamiento e incluso variables alternativas (como metadatos demográficos o transaccionales) de un solicitante de crédito (MathWorks, s.f.; Kästner, 2021). El objetivo del algoritmo es aproximar una función predictiva $h(X)$ que mapee estas características a una etiqueta de salida $Y \in \{0, 1\}$, donde $Y=1$ denota que el solicitante será solvente (comportamiento crediticio favorable/buen pagador) e $Y = 0$ representa un evento de default (morosidad o impago) (Angwin et al., 2016; MathWorks, s.f.).

A diferencia de las tarjetas de puntuación lineales basadas en regresión logística clásica, las arquitecturas modernas de Machine Learning (tales como *Random Forests*, *Decision Trees* o modelos basados en *Gradient Boosting*) permiten capturar de forma robusta complejas interacciones no lineales de alta dimensionalidad entre las variables financieras, reduciendo drásticamente la tasa de falsos negativos (MathWorks, s.f.). Sin embargo, la inclusión de múltiples variables proxies correlacionadas con atributos demográficos protegidos incrementa masivamente el riesgo de introducir discriminación algorítmica encubierta (Anders et al., 2020; MathWorks, s.f.). Por consiguiente, integrar compuertas de aseguramiento continuo de calidad ética en las canalizaciones de MLOps no representa únicamente un esfuerzo técnico por optimizar el cálculo de la ECL, sino que constituye un estricto imperativo legal y ético para garantizar un acceso financiero justo, transparente y plenamente auditable (MathWorks, s.f.).

2.1.2 El sesgo algorítmico y la equidad en el Scoring Crediticio

En la ingeniería de software orientada a sistemas inteligentes, el sesgo algorítmico se define como el sesgo sistemático y repetible de un modelo de *Machine Learning* que produce resultados discriminatorios o desproporcionadamente desfavorables contra ciertos subgrupos demográficos (Adebayo & Kegal, 2016; Russo et al., 2024; Russo & Vidal, 2025). El origen de este sesgo es diverso, clasificándose principalmente en (Russo et al., 2024; Russo & Vidal, 2025):

1. **Sesgo histórico o social:** Proveniente de desigualdades arraigadas en la sociedad que quedan registradas de manera inherente en los datos históricos de entrenamiento (Russo et al., 2024; Russo & Vidal, 2025).
2. **Sesgo de representación o muestreo:** Ocurre cuando el tamaño de la muestra de un subgrupo específico (minoría) está subrepresentado estadísticamente en el lote de datos, impidiendo que el algoritmo generalice adecuadamente para dicha población (Russo & Vidal, 2025). En el ecosistema financiero global, este sesgo afecta de forma estructural a los perfiles *thin-file* (poblaciones informales o sin historial crediticio previo). Para mitigar esta subrepresentación, las instituciones suelen ingestar "datos alternativos" (metadatos de dispositivos móviles, historiales de navegación o pagos de servicios no financieros); sin embargo, si estas nuevas fuentes de datos provienen mayoritariamente de poblaciones urbanas o digitalizadas, el sesgo de representación se perpetúa y amplifica contra los sectores rurales o vulnerables (Demirgüç-Kunt et al., 2022).
3. **Sesgo de medición:** Introducido por errores sistemáticos durante la recolección o etiquetado de la información, o debido al uso de variables sustitutas (*proxies*) inadecuadas para estimar el objetivo de negocio (Russo & Vidal, 2025). La dependencia de datos alternativos exacerba este riesgo, ya que estas variables conductuales a menudo contienen alto ruido estadístico y actúan como indicadores defectuosos que terminan midiendo la capacidad adquisitiva o el nivel de pobreza estructural del individuo, en lugar de evaluar su verdadera voluntad de pago o solvencia moral.

En los sistemas de *scoring* crediticio, la discriminación suele manifestarse de forma indirecta mediante la discriminación por proxy (Russo & Vidal, 2025). Este fenómeno ocurre cuando se excluyen explícitamente variables sensibles o atributos protegidos Z (e.g., género, origen étnico) del entrenamiento del

modelo, técnica conocida como *Fairness through Unawareness*, pero el algoritmo logra reconstruir la información protegida utilizando variables sustitutas X correlacionadas (e.g., el código de zona postal, nivel educativo o estado civil) (Russo & Vidal, 2025; Russo et al., 2024). Por consiguiente, el aseguramiento de la equidad (*fairness*) requiere metodologías capaces de auditar y mitigar activamente la propagación de estos patrones discriminatorios en todo el ciclo de vida del software (Russo & Vidal, 2025).

2.1.3 Métricas matemáticas de Equidad de Grupo

La literatura de Inteligencia Artificial Confiable (*Trustworthy AI*) divide formalmente las métricas cuantitativas en dos grandes dimensiones: la equidad de grupo y la equidad individual (Mehrabi et al., 2021). La equidad de grupo busca asegurar que subgrupos definidos por un atributo protegido (e.g., mujeres vs. hombres, jóvenes vs. adultos) reciban en agregado un trato similar en los resultados predictivos del modelo (Mehrabi et al., 2021).

Sea $Y \in \{0, 1\}$ la etiqueta real de solvencia (donde 1 representa comportamiento crediticio favorable/buen pagador y 0 representa incumplimiento), $\hat{Y} \in \{0, 1\}$ la predicción del modelo de scoring, y $Z \in \{0, 1\}$ el atributo protegido (donde $Z = 0$ denota al grupo desfavorecido o no privilegiado y $Z = 1$ al grupo privilegiado) (Russo et al., 2024; Russo & Vidal, 2025). Las tres métricas de grupo fundamentales aplicadas al scoring crediticio se formulan matemáticamente de la siguiente manera:

- **Diferencia de Paridad Estadística o Paridad Demográfica (SPD):** Exige que la probabilidad de recibir una predicción de crédito aprobada ($\hat{Y} = 1$) sea independiente de pertenecer al grupo sensible (Russo et al., 2024; Russo & Vidal, 2025; Biswas & Rajan, 2021). Se define como:
$$SPD = P(\hat{Y} = 1 | Z = 0) - P(\hat{Y} = 1 | Z = 1)$$
 Un valor de SPD cercano a 0 representa condiciones perfectas de paridad. Valores negativos indican sesgo perjudicial contra el grupo no privilegiado (Zhu et al., 2025).
- **Diferencia de Igualdad de Oportunidades (EOD):** Criterio canónico de equidad propuesto originalmente por Hardt et al. (2016) que evalúa la equidad únicamente sobre aquellos solicitantes de crédito que verdaderamente son solventes ($Y = 1$), exigiendo que la tasa de verdaderos positivos (TPR) sea equivalente entre ambos grupos (Russo et

al., 2024; Russo & Vidal, 2025; Biswas & Rajan, 2021). Se formula como: $EOD = P(\hat{Y} = 1 \mid Y = 1, Z = 0) - P(\hat{Y} = 1 \mid Y = 1, Z = 1)$ Esta métrica es crítica en finanzas, ya que garantiza que los buenos pagadores tengan la misma tasa de aprobación de crédito independientemente de su grupo demográfico (Russo & Vidal, 2025; Biswas & Rajan, 2021).

- **Impacto Dispar (DI):** Es una métrica de ratio o cociente entre las tasas de selección favorable de ambos grupos (Russo et al., 2024; Russo & Vidal, 2025; Biswas & Rajan, 2021): $DI = \frac{P(\hat{Y} = 1 \mid Z = 0)}{P(\hat{Y} = 1 \mid Z = 1)}$. La regla de los cuatro quintos (establecida por la EEOC de EE. UU.) considera que existe un impacto dispar o discriminación indirecta sustancial si el cociente DI es menor que 0.80 (Russo & Vidal, 2025; Zafar et al., 2019; Biswas & Rajan, 2021).

2.1.4 Métricas matemáticas de Equidad Individual y Multiplicidad

A diferencia del enfoque de grupo, la equidad individual parte de la premisa filosófica de que "individuos similares deben recibir resultados similares" (Angwin et al., 2016; Mehrabi et al., 2021). Es un enfoque micro centrado en el sujeto que complementa las métricas macro de distribución (Angwin et al., 2016; Mehrabi et al., 2021).

- **Consistencia (Consistency):** Cuantifica la similitud local entre las decisiones del algoritmo evaluando la cercanía en el espacio euclídeo de características. Se mide comparando la predicción de una instancia x frente a las predicciones del modelo sobre sus k vecinos más cercanos (típicamente $k = 5$) (Mehrabi et al., 2021): $Consistency(x) =$

$$1 - \frac{1}{k} \sum_{x_j \in k-NN(x)} |Y(x) - Y(x_j)|.$$

- **Puntuación de Discriminación Causal (CDS):** Cuantifica la robustez individual simulando un escenario contrafactual (Li et al., 2023; Biswas & Rajan, 2021). Para un sujeto dado, se perturba sintéticamente el valor de su atributo protegido (e.g., modificando el género de femenino a masculino en la solicitud de crédito) manteniendo constantes las demás variables de características (Li et al., 2023; Biswas & Rajan, 2021). El CDS registra el porcentaje de veces que esta alteración aislada altera la

predicción final de otorgamiento, evidenciando una dependencia causal indeseable de la decisión algorítmica respecto al atributo sensible (Li et al., 2023; Biswas & Rajan, 2021).

- **Injusticia por exclusión de uno (Leave-One-Out Unfairness - LUF):** Formaliza conceptualmente la arbitrariedad inherente de las reglas de decisión de un modelo (Black & Fredrikson, 2021; Mehrabi et al., 2021). LUF mide la probabilidad en el peor escenario de que el resultado predictivo para un individuo x se vea modificado simplemente por haber excluido una sola instancia de datos aleatoria del lote de datos con el que se entrenó originalmente el modelo (Black & Fredrikson, 2021; Biswas & Rajan, 2021):

$$LUF(h, S, x) = \max_i |P(h_S(x) = \hat{y}) - P(h_{S \setminus \{z_i\}}(x) = \hat{y})|$$

Un LUF elevado demuestra que la decisión sobre un solicitante de crédito depende de factores de muestreo fortuitos e irrelevantes para su solvencia, careciendo de justabilidad o explicabilidad técnica estable (Black & Fredrikson, 2021).

2.1.5 Degradación del sistema: Drift de Datos, de Concepto y de Sesgo

La estabilidad de un clasificador de riesgo crediticio es inherentemente inestable debido a que las condiciones macroeconómicas y demográficas en entornos en producción cambian constantemente en comparación con el entorno histórico estático en el que el modelo fue entrenado (Avuthu, 2021; Reda et al., 2025).

Esta degradación de calidad se caracteriza por tres fenómenos:

1. **Deriva de datos (*Data Drift*):** Desviación sistemática en la distribución de las variables de entrada del modelo predictivo $P(X)$ provocada por cambios poblacionales o de mercado (Avuthu, 2021; Reda et al., 2025).
2. **Deriva de concepto (*Concept Drift*):** Cambio gradual o repentino en la relación matemática real entre las variables de entrada y la variable objetivo $P(Y | X)$ (e.g., variaciones en las tasas de morosidad ante fluctuaciones en las tasas de interés) (Avuthu, 2021; Reda et al., 2025).
3. **Deriva del sesgo (*Bias Drift*):** Consecuencia operativa donde el modelo, al interactuar con datos reales desviados en producción, altera sus tasas de

error grupal e inyecta disparidades éticas imprevistas que violan los umbrales de equidad originalmente garantizados en desarrollo (Reda et al., 2025). Esto justifica la necesidad de integrar un monitoreo continuo de métricas en producción para disparar reentrenamientos seguros (Reda et al., 2025).

2.1.6 El dilema de Precisión frente a Equidad (Accuracy-Fairness Trade-off)

En la optimización tradicional de algoritmos de aprendizaje automático, el objetivo matemático principal es minimizar una función de pérdida empírica $L(\hat{Y}, Y)$ para maximizar métricas de rendimiento predictivo, tales como la exactitud (*Accuracy*) o el área bajo la curva ROC (ROC-AUC). Sin embargo, la evidencia científica demuestra que la imposición de restricciones matemáticas para satisfacer criterios estrictos de equidad de grupo, tales como llevar la Diferencia de Paridad Estadística (SPD) o la Diferencia de Igualdad de Oportunidades (EOD) a un valor de 0, actúa como una penalización de regularización que aleja al algoritmo de su solución predictiva óptima. Este fenómeno estructural se conoce formalmente como el dilema de precisión frente a equidad (*Accuracy-Fairness Trade-off*) (Menon & Williamson, 2018).

En el contexto de la gestión del riesgo de crédito, este *trade-off* posee implicaciones operativas y financieras críticas. Cualquier degradación en el poder predictivo del algoritmo se traduce intrínsecamente en un aumento de la tasa de falsos positivos (aprobar crédito a malos pagadores) o falsos negativos (rechazar a clientes financieramente solventes). Dado que las normativas internacionales establecen que el cálculo de la Pérdida Esperada (ECL) depende directamente de la precisión en la estimación de la Probabilidad de Default (PD), un modelo que sacrifique excesivamente su exactitud para forzar una equidad estadística perfecta desestabiliza el perfil de riesgo de la entidad.

Por consiguiente, el aseguramiento de calidad algorítmica no persigue la eliminación absoluta e incondicional de las disparidades, sino la optimización sobre la frontera de Pareto (*Pareto frontier*) entre la precisión y la equidad (Menon & Williamson, 2018). Este dilema justifica la aplicación del principio de multiplicidad del modelo para fines de auditoría. La arquitectura MLOps diseñada en esta investigación emplea los "Contratos de Equidad" no sólo como mecanismos de bloqueo, sino para facilitar la búsqueda sistemática e iterativa de

aquel clasificador que ofrezca el menor impacto dispar posible entre todos los modelos estadísticamente equivalentes en su precisión predictiva, garantizando un despliegue operativo que sea simultáneamente ético, legal y rentable.

2.2 Marco Teórico

Esta sección detalla los paradigmas y marcos metodológicos de la ingeniería de software y operaciones que estructuran el diseño tecnológico de la arquitectura MLOps.

2.2.1 El paradigma MLOps y la automatización CI/CD

El paradigma MLOps (Machine Learning Operations) constituye una cultura y un conjunto de prácticas de ingeniería de software orientadas a unificar de manera confiable el desarrollo (Dev) y la operación (Ops) de sistemas basados en aprendizaje automático en producción (Kazmierczak et al., 2024; Russo et al., 2024). Para mitigar las validaciones manuales aisladas del Nivel 0 de madurez, es imperativo establecer canalizaciones (*pipelines*) de MLOps de Nivel 2 basadas en la orquestación de Integración Continua (CI), Entrega Continua (CD) y Entrenamiento Continuo (CT) (Kazmierczak et al., 2024).

La CI automatiza la compilación, ejecución de aserciones de código y empaquetamiento del software ante cualquier confirmación en el repositorio de código fuente (Kazmierczak et al., 2024). En MLOps, la CI debe validar activamente la integridad de los datos, los esquemas de entrada y la robustez del modelo predictivo (Kazmierczak et al., 2024). La CD automatiza el despliegue rápido del modelo validado hacia el entorno de simulación (*staging*) o producción local (Kazmierczak et al., 2024). Finalmente, el CT automatiza la ejecución periódica del pipeline de entrenamiento a partir de nuevos lotes de datos limpios, activado por alertas de deriva o decaimiento de rendimiento emitidas por herramientas de monitoreo en producción (Kazmierczak et al., 2024).

2.2.2 Aseguramiento de Calidad proactivo: Shift-Left Testing y Contratos de Equidad

Las canalizaciones tradicionales de Machine Learning adolecen de un enfoque tardío del aseguramiento de calidad, evaluando la equidad únicamente como un análisis de caja negra sobre el artefacto predictivo final ya desplegado (Biswas & Rajan, 2021). Sin embargo, la investigación demuestra que el sesgo algorítmico es de naturaleza composicional (Biswas & Rajan, 2021). Las transformaciones secuenciales e intermedias de características, tales como la imputación de nulos mediante estimaciones o el escalado numérico de variables, introducen desviaciones sutiles que actúan de manera aditiva e inyectan sesgos éticos que no se originaron en el conjunto de datos de entrada crudo (Biswas & Rajan, 2021).

Para solucionar esto, la arquitectura propuesta adopta el principio metodológico de Shift-Left Testing de la ingeniería de software, el cual desplaza las actividades de prueba e inspección de calidad hacia las etapas más tempranas posibles de la canalización de desarrollo (Biswas & Rajan, 2021; Nguyen, 2024). Este principio se operativiza mediante el Diseño por Contratos de Equidad (Fairness Contracts) (Nguyen, 2024).

Basados en el paradigma clásico de *Design by Contract (DbC)*, los contratos de equidad aplican aserciones y restricciones matemáticas en tiempo de ejecución (precondiciones y postcondiciones) sobre módulos individuales del pipeline (Nguyen, 2024). Si un preprocesador o estimador específico viola el umbral ético definido de forma declarativa (e.g., un archivo de configuración en formato YAML), el orquestador CI/CD (e.g., Pytest + GitHub Actions) interrumpe inmediatamente el flujo con un código de salida fallido (exit 1) a través de Compuertas de Calidad (QA Gates), impidiendo de forma proactiva la propagación del defecto y permitiendo la rápida localización e identificación de la causa raíz (Nguyen, 2024).

2.2.3 Trazabilidad semántica mediante Grafos de Conocimiento (RDF/OWL)

Localizar e interrumpir un despliegue éticamente comprometido en la etapa de CI/CD es insuficiente si la organización no puede documentar ni explicar la trazabilidad de sus decisiones algorítmicas ante entes reguladores o equipos de auditoría interna (Ogrizović et al., 2024; Kazmierczak et al., 2024). Esto exige el registro del linaje de datos (provenance), el cual mapea la historia de transformaciones que sufre cada registro de datos individuales a lo largo de los

operadores del pipeline de Machine Learning (Russo et al., 2024; Russo & Vidal, 2025).

Para que este linaje de datos sea inteligible, uniforme y estructurado tanto para máquinas como para humanos, la propuesta de solución integra la Trazabilidad Semántica mediante Grafos de Conocimiento utilizando estándares establecidos por la World Wide Web Consortium (W3C) (Russo et al., 2024; Russo & Vidal, 2025). Mediante el formato RDF (Resource Description Framework), los metadatos de los experimentos (hiperparámetros de MLflow, hashes de datos de DVC, resultados de las QA Gates y puntuaciones de explicabilidad local calculadas mediante SHAP) se serializan en forma de tripletas factuales estructuradas (sujeto, predicado, objeto) (Russo et al., 2024; Russo & Vidal, 2025).

Para regular el vocabulario y garantizar la interoperabilidad semántica del grafo resultante, se define una ontología formal en OWL (Web Ontology Language) que describe las relaciones conceptuales entre componentes de datos, variables demográficas, tipos de sesgos y métricas éticas (Russo et al., 2024; Russo & Vidal, 2025). Este grafo de conocimiento unificado se almacena de manera local en un repositorio de triples RDF nativo (GraphDB), permitiendo a auditores técnicos o legales ejecutar consultas declarativas complejas en lenguaje SPARQL para reconstruir de forma automática, incorruptible e íntegra el reporte documental de cumplimiento y auditoría de equidad exigido por las regulaciones financieras globales (Nguyen, 2024; Russo et al., 2024).

2.3 Marco Legal

2.3.1 Ley de IA de la Unión Europea (EU AI Act - Reglamento UE 2024/1689)

Sancionado de manera formal el 13 de junio de 2024, representa la legislación horizontal en gobernanza de inteligencia artificial más influyente del mundo (Reglamento IA UE, 2024). Su enfoque metodológico se fundamenta en una clasificación proporcional basada en el riesgo, identificando categorías específicas de riesgo inaceptable (prohibidas), riesgo alto, riesgo de transparencia específica y riesgo mínimo (Reglamento IA UE, 2024).

De acuerdo con el Anexo III, punto 5.b del reglamento, se clasifican explícitamente como sistemas de IA de alto riesgo a aquellos que estén

destinados a utilizarse para evaluar la solvencia de personas físicas o establecer su calificación crediticia (scoring) (Reglamento IA UE, 2024). Esta clasificación legal impone de forma obligatoria y punible a los proveedores y responsables del despliegue financiero el cumplimiento de exigencias técnicas rigurosas (Reglamento IA UE, 2024):

- **Gobernanza y calidad de datos (Art. 10):** El reglamento exige de manera imperativa implementar prácticas de gestión de datos, incluyendo la evaluación y mitigación proactiva de posibles sesgos discriminatorios sistemáticos (Reglamento IA UE, 2024).
- **Trazabilidad y registro técnico (Art. 11 y 12):** Exige mantener la documentación técnica actualizada e integrar mecanismos de registro automático de acontecimientos mediante archivos de registro (*logs*) a lo largo de toda la vida útil de los sistemas de alto riesgo para garantizar su auditabilidad por terceros (Reglamento IA UE, 2024).
- **Evaluación de impacto sobre los derechos fundamentales (Art. 29a / 96):** Obliga a entidades de servicios financieros a ejecutar una evaluación detallada para mitigar riesgos en derechos humanos antes del despliegue, documentando las salvaguardias técnicas implementadas (Reglamento IA UE, 2024).
- **La paradoja de la privacidad y el procesamiento de datos sensibles (Art. 10.5):** Un desafío estructural en la auditoría algorítmica es la fricción legal entre las normativas globales de protección de datos (como el GDPR europeo o la Ley de Protección de Datos Personales en Perú) y la evaluación matemática de la equidad. Para que herramientas como AIF360 o Fairlearn puedan cuantificar métricas grupales de disparidad, el pipeline de Machine Learning requiere ingerir y procesar obligatoriamente el atributo protegido Z (por ejemplo, el origen étnico o género). Para resolver esta paradoja jurídica, el Reglamento de IA introduce una excepción explícita en su Artículo 10, apartado 5. Esta cláusula permite a los proveedores de sistemas de IA de alto riesgo procesar categorías especiales de datos personales, de manera estricta y exclusiva, con el propósito de detectar, monitorear y corregir sesgos algorítmicos (Reglamento IA UE, 2024). Esta facultad excepcional está condicionada a la implementación de salvaguardias técnicas inviolables, como la seudonimización y el cifrado de última generación (Reglamento IA UE, 2024). En el contexto de la presente investigación, esta exigencia regulatoria fundamenta la inclusión del componente de "Captura y

anonimización" dentro de la Zona 3 (Producción) de la arquitectura diseñada, garantizando que el monitoreo de la deriva del sesgo (*bias drift*) se ejecute en estricto cumplimiento legal.

2.3.2 Normativa de Equidad en Finanzas Globales (ECOA de Estados Unidos)

En el ecosistema financiero internacional, la legislación estadounidense bajo la Equal Credit Opportunity Act (ECOA - Public Law 93-495) establece que es ilegal que un acreedor discrimine a cualquier solicitante de crédito basándose en atributos protegidos como la raza, género, estado civil, edad o religión (Equal Credit Opportunity Act [ECOA], 1974). El marco de la ECOA es de gran trascendencia global debido a que tipifica formalmente la doctrina de impacto dispar (*disparate impact doctrine*) (Equal Credit Opportunity Act [ECOA], 1974; Bartlett et al., 2022).

Bajo este principio legal, una práctica crediticia neutral en apariencia—como el uso de un clasificador de Machine Learning complejo—se considera ilegal si genera resultados desproporcionadamente desfavorables contra un grupo protegido, a menos que el prestamista pueda justificar que la variable o modelo responde a una "necesidad de negocio legítima que no puede razonablemente lograrse de manera igualmente eficaz por medios menos discriminatorios" (Bartlett et al., 2022). Asimismo, en lo que respecta a la explicabilidad y el derecho a recibir una justificación clara, la Circular 2023-03 de la Oficina para la Protección Financiera del Consumidor (CFPB, 2023) establece taxativamente que el uso de algoritmos complejos de tipo "caja negra" no exime a los prestamistas de la obligación de proporcionar razones específicas y precisas para denegar un crédito (Adverse Action Notice bajo la Regulation B de la ECOA). Esta exigencia de transparencia fundamenta de manera regulatoria directa la necesidad de integrar técnicas de atribución local de características, como SHAP, en el pipeline de producción para automatizar explicaciones justificables.

2.3.3 Estándar Internacional de Gestión de IA (ISO/IEC 42001)

Publicado de manera reciente, este estándar internacional define los requisitos para establecer, implementar, mantener y mejorar de forma continua un Sistema de Gestión de Inteligencia Artificial (AIMS) dentro de una organización. El

estándar exige documentar y auditar sistemáticamente los objetivos de equidad de los algoritmos de la empresa, gestionar los riesgos de sesgo técnico en los datos, y estructurar metodologías estandarizadas de aseguramiento de calidad (QA) y registros de trazabilidad reproducibles para demostrar de forma robusta la debida diligencia de gobernanza corporativa, alineando la presente tesis con las mejores prácticas mundiales de ingeniería de software ético (ISO/IEC 42001, 2023; Reglamento IA UE, 2024).

Capítulo 3. Estado del Arte

3.1 Introducción

El presente capítulo tiene como objetivo revisar y analizar la literatura científica reciente sobre la implementación de la validación de equidad dentro del ciclo de vida del aprendizaje automático. Para estructurar adecuadamente este estado del arte, la introducción se divide en tres enfoques fundamentales: la conceptualización de *MLOps* como estándar de la industria, las problemáticas previamente abordadas por la comunidad científica, y los vacíos específicos que la presente investigación buscará resolver en el marco de la calidad de software.

Es fundamental definir el concepto de *MLOps* (*Machine Learning Operations*). *MLOps* es una práctica y cultura de la ingeniería que busca unificar el desarrollo y las operaciones de los sistemas de aprendizaje automático, con el objetivo de abogar por la automatización y la supervisión en todos los pasos de la construcción del sistema. En el entorno empresarial, la adopción de *MLOps* es indispensable para transitar de procesos de validación puramente manuales y aislados —conocidos como Nivel 0 de *MLOps*— hacia canalizaciones (*pipelines*) robustas que garanticen la Integración Continua (CI), Entrega Continua (CD) y Entrenamiento Continuo (CT) (Kazmierczak et al., 2024; Reda et al., 2025).

En los últimos años, la investigación del estado del arte en *MLOps* ha abordado extensamente la gestión del ciclo de vida de los modelos, la reproducibilidad y el despliegue a gran escala mediante el uso de plataformas infraestructurales. Sin embargo, la literatura reciente advierte que gran parte de la investigación debe volcarse a mitigar los "errores de distribución de datos", los cuales introducen sesgos técnicos y discriminación de manera silenciosa durante las etapas tempranas de preprocesamiento (Grafberger et al., 2022). Además, se ha evidenciado el desafío de evaluar las canalizaciones como una "caja negra" monolítica, destacando la necesidad de analizar la equidad de forma modular para identificar exactamente qué etapa o componente inyecta el sesgo en el modelo (Biswas & Rajan, 2021). Para mitigar estos riesgos, diversas investigaciones han propuesto herramientas de depuración de datos y métricas de equidad; no obstante, la mayoría de los enfoques actuales siguen concibiendo el cumplimiento ético como auditorías manuales externas o pruebas tardías previas al despliegue, en lugar de intervenciones proactivas y oportunas para evitar la amplificación del sesgo (Vasquez et al., 2023).

A partir de las limitaciones identificadas en la literatura, esta investigación solucionará las deficiencias metodológicas y arquitectónicas en la integración de la validación continua de equidad como una prueba de aseguramiento de calidad intrínseca, automatizada y auditable dentro del ciclo de vida de *MLOps*. A diferencia de los enfoques que dependen de validaciones estáticas, este trabajo abordará el problema de diseñar una arquitectura proactiva que implemente compuertas de calidad capaces de interrumpir la canalización de integración continua y bloquear de forma preventiva el despliegue de modelos sesgados (Schelter et al., 2023; Zhu et al., 2025). Adicionalmente, la investigación enfrentará la actual falta de trazabilidad semántica en las herramientas *MLOps*

tradicionales, proponiendo el uso de grafos de conocimiento y ontologías para generar artefactos documentados estandarizados (Russo & Vidal, 2025; Russo et al., 2024). Esta infraestructura documental y de calidad es hoy un requisito indispensable para mitigar riesgos éticos y facilitar el cumplimiento de marcos globales de Gestión de Riesgos de Modelos (IBM, s.f.), respondiendo así a las nuevas normativas internacionales, como la Ley de Inteligencia Artificial de la Unión Europea (AI Act), que exige niveles apropiados de robustez, resiliencia y documentación continua para sistemas de IA de alto riesgo (Wagner, 2024; Zhu et al., 2025).

3.2 Objetivos de revisión

El objetivo de esta revisión sistemática es identificar, analizar y comparar las arquitecturas y marcos de trabajo MLOps más relevantes aplicados a la validación continua de equidad en modelos predictivos supervisados. La revisión se orienta a sintetizar la evidencia empírica disponible sobre las estrategias de integración continua, los mecanismos de control de calidad temprana y la trazabilidad documental, con el fin de detectar las limitaciones de los enfoques tradicionales y fundamentar técnica y metodológicamente la propuesta arquitectónica de esta investigación.

Para alcanzar este propósito general, se plantean los siguientes objetivos específicos de revisión:

- **Revisar los procesos tradicionales de validación de modelos** de aprendizaje automático, identificando sus inefficiencias y limitaciones estructurales para la detección proactiva de sesgos algorítmicos.
- **Examinar las arquitecturas y patrones de diseño MLOps actuales** que incorporan la evaluación de equidad de manera modular, evaluando su impacto en la automatización frente a los enfoques de "caja negra".
- **Analizar la implementación de compuertas de calidad** y marcos de pruebas de estrés automatizados dentro de la canalización de integración continua orientados a bloquear el despliegue de modelos sesgados.
- **Identificar las herramientas de monitoreo continuo y trazabilidad semántica** (basadas en grafos de conocimiento u ontologías) utilizadas en la literatura para registrar el ciclo de vida del modelo y generar documentación auditable orientada al cumplimiento normativo.




Figura 2: Arquitectura del sistema (Nivel 2 de Diagrama C4)

3.3 Preguntas de revisión

Como medida para estructurar el planteamiento de la revisión sistemática, se presenta a continuación el conjunto de preguntas que guiarán la investigación. La formulación de estas preguntas se deriva directamente del objetivo de revisión planteado en la sección anterior.

Para asegurar una estructura clara y delimitar con precisión el alcance de la búsqueda bibliográfica, la formulación se ha guiado por los criterios del marco PICOC (Petticrew & Roberts, 2006) y se puede observar en la Tabla 6.

Metodología	Descripción
Población	Modelos de Aprendizaje Supervisado en entornos de producción y flujos de trabajo <i>MLOps</i> .
Intervención	La implementación de arquitecturas o herramientas de validación continua de equidad automatizada dentro del <i>pipeline</i> de <i>MLOps</i> .
Comparación	Los métodos de auditoría tradicionales.
Resultado	La efectividad, medida en términos de capacidad de detección de sesgos , automatización del proceso de calidad y mitigación de riesgos éticos antes y después del despliegue.

Contexto	En el ámbito del desarrollo de software y ciencia de datos, aplicable a organizaciones que despliegan modelos de IA, con énfasis en sectores regulados o de impacto social.
-----------------	---

Tabla 6 Criterios Generales PICOC

De este modo, a partir de los resultados de la Tabla 6 se plantean las siguientes preguntas de revisión:

1. ¿Qué problemas o ineficiencias clave enfrentan los procesos tradicionales de validación de modelos (auditorías manuales o desconectadas del flujo de desarrollo) en la detección de sesgos en *Machine Learning*?
2. ¿Qué arquitecturas, herramientas y patrones de diseño *MLOps* existen actualmente para la validación de equidad, y cómo facilitan la detección proactiva y la evaluación modular frente a los enfoques tradicionales de "caja negra"?
3. ¿Qué mecanismos de control de calidad (*QA Gates*) y monitoreo continuo se implementan en las arquitecturas *MLOps* para bloquear el despliegue de modelos sesgados y mitigar la deriva de sesgo (*bias drift*) en producción?
4. ¿Qué desafíos técnicos y de interoperabilidad presentan las herramientas de validación de equidad para integrarse en *pipelines MLOps* empresariales, y cómo abordan la trazabilidad semántica para la generación de documentación auditable?

3.4 Protocolo de búsqueda

El protocolo de búsqueda a seguir plantea la identificación y selección sistemática de documentos (artículos de conferencia y revistas científicas) que estén relacionados con el estado actual de las arquitecturas para la validación de equidad en flujos de trabajo de *Machine Learning* (MLOps).

Para construir las cadenas de búsqueda, se utilizaron los términos y conceptos clave definidos en el marco PICOC (Petticrew & Roberts, 2006) de la sección anterior. Este método permitió desglosar el problema en sus componentes principales (Población, Intervención, Comparación, Outcome) para derivar

sinónimos y términos de búsqueda relevantes en idioma inglés y español, asegurando una cobertura amplia de la literatura técnica y científica.

El proceso se detalla en las siguientes sub-secciones, describiendo los motores de búsqueda seleccionados por su relevancia académica y las cadenas de búsqueda específicas empleadas para cada uno.

3.4.1 Motores de búsqueda

Para la elección de los motores de búsqueda, se selecciona un subconjunto de bases de datos como medio para optar por la documentación necesaria durante el proceso de revisión sistemática. Las bases de datos elegidas fueron:

- **Scopus** (<https://www.scopus.com>): Se selecciona esta base de datos por ser uno de los mayores repositorios multidisciplinarios de resúmenes y citas de literatura científica revisada por pares. Su relevancia radica en que indexa una gran cantidad de conferencias y revistas de alto impacto, permitiendo una visión global del estado del arte.
- **IEEE Xplore** (<https://ieeexplore.ieee.org>): Se incluye esta biblioteca digital por ser la fuente más prestigiosa en los campos de ingeniería eléctrica, ciencias de la computación y electrónica. Dado que el enfoque de la tesis es la arquitectura de software (*MLOps*), esta base es crítica para encontrar estándares técnicos y estudios de implementación recientes.
- **Google Académico** (<https://scholar.google.com/>): Se utilizará como un motor de búsqueda complementario. Su amplio índice es útil para capturar "literatura gris" (como reportes técnicos o *pre-prints*) y estudios en español que podrían no estar indexados en las bases de alto impacto.

3.4.2 Cadenas de búsqueda a usar

A partir del marco PICOC (Petticrew & Roberts, 2006) definido en la sección anterior, se tomaron en cuenta los componentes de la investigación para seleccionar los términos clave en español e inglés. Esto aborda la necesidad de un proceso explícito para derivar los términos de búsqueda, tal como se muestra en la Tabla 7.

Metodología	Palabras clave en español	Palabras clave en inglés
Población	"Operaciones de Aprendizaje de Máquina", "Aprendizaje Supervisado", "flujo MLOps"	"Machine Learning operations", "MLOps", "Supervised Learning", "MLOps pipeline"
Intervención	"Validación de equidad", "Detección de sesgos", "Auditoría algorítmica"	"Fairness validation", "Bias detection", "Algorithmic auditing", "performance evaluation"
Comparación	"Validación manual", "Pruebas tradicionales"	"Manual validation", "Traditional testing"
Resultado	"Mitigación de sesgos", "IA confiable", "Calidad de software"	"Bias mitigation", "Trustworthy AI", "Software Quality Assurance"
Contexto	"Ingeniería de software", "Sistemas en producción"	"Software Engineering", "Production systems"

Tabla 7 Cadenas de búsqueda

Para la revisión de literatura se aplicó una ecuación general de búsqueda construida a partir del marco PICOC, adaptándola a cada base de datos, las cuales se muestran en la Tabla 8. Se utilizaron términos en inglés (predominantes en el área tecnológica) y en español para ampliar los resultados

y asegurar la inclusión de artículos relevantes, dejando como resultado un total de 128 resultados en la base de datos de Scopus, 30 en IEEE Xplore y 54 en la base de datos de Google Académico.

Asimismo, se desarrollaron diferentes ecuaciones de búsqueda (Tabla 8) dependiendo de cada base de datos, ya que en principio cada una de estas cumple con lo obtenido luego de la metodología PICOC. No obstante, debido a la naturaleza técnica del tema, el uso de términos en inglés influye enormemente en la obtención de resultados relevantes.

Base de datos	Palabras / Ecuación de búsqueda
Scopus	(TITLE-ABS-KEY ("MLOps" OR "Machine Learning Operations" OR "ML pipeline" OR "CD4ML") AND TITLE-ABS-KEY ("fairness" OR "bias" OR "equity" OR "trustworthy AI"))
IEEEExplore	("MLOps" OR "Machine Learning Operations" OR "ML pipeline") AND ("fairness" OR "bias" OR "equity" OR "ethical AI")
Google Académico	"MLOps" AND ("fairness" OR "bias" OR "equidad") AND ("validation" OR "auditing")

Tabla 8 Ecuación de búsqueda en las bases de datos

3.5 Criterios de inclusión y exclusión

Para la selección de los estudios primarios, se definieron criterios de inclusión (CI) y exclusión (CE) alineados con las preguntas de investigación y el objetivo de diseñar una arquitectura MLOps.

Criterios de Inclusión (CI):

- CI-1 (Temporalidad): Estudios publicados entre el año 2019 y 2026, para garantizar la vigencia tecnológica de las herramientas MLOps y algoritmos de mitigación de sesgo.
- CI-2 (Temática): Artículos que aborden explícitamente MLOps (Machine Learning Operations), *Fairness* (Equidad algorítmica), *Bias Mitigation* (Mitigación de sesgos) o *Trustworthy AI* en *pipelines* de datos.
- CI-3 (Tipo de Datos): Investigaciones centradas en datos estructurados o tabulares (e.g., CSV, bases de datos relacionales, registros financieros), dado el alcance de la arquitectura propuesta.
- CI-4 (Nivel Técnico): Estudios que proponen arquitecturas de software, algoritmos, herramientas implementables o marcos metodológicos/conceptuales. Se incluirán tanto las investigaciones con validación experimental, como aquellos estudios teóricos o regulatorios que aporten lineamientos de diseño, metodologías de pruebas de calidad (*QA*) o requisitos técnicos aplicables directamente al ciclo de vida del Machine Learning (*MLOps*).
- CI-5 (Idioma): Publicaciones redactadas en inglés o español.

Criterios de Exclusión (CE):

- CE-1 (Dominio Irrelevante): Estudios enfocados exclusivamente en datos no estructurados (visión artificial, procesamiento de audio o video) cuyas técnicas no son transferibles directamente a tareas de clasificación en datos estructurados.
- CE-2 (Falta de Aplicabilidad): Se excluirán artículos puramente filosóficos, sociológicos o legales que no tengan relación con el ciclo de vida del software. Sin embargo, sí se incluirán estudios teóricos, revisiones legales o marcos conceptuales (*frameworks*) siempre y cuando aborden cómo traducir principios éticos o regulatorios en requisitos de calidad (*QA*), pruebas de software o metodologías para *MLOps*.
- CE-3 (Tecnología Obsoleta): Propuestas que utilicen enfoques de ML monolíticos (sin *pipelines*) o herramientas discontinuadas anteriores al auge de MLOps moderno.
- CE-4 (Indisponibilidad de Texto Completo): Artículos cuyo contenido completo no pudo ser recuperado a través de las bases de datos

institucionales suscritas, repositorios de acceso abierto (*Open Access*) o contacto directo con los autores.

La selección de los estudios primarios se llevó a cabo siguiendo las cuatro fases del flujo PRISMA (Identificación, Cribado, Elegibilidad e Inclusión), aplicando rigurosamente los criterios definidos en la sección anterior.

1. Identificación (Fase 1): En esta etapa inicial, se realizó la búsqueda sistemática en las fuentes de información seleccionadas, recuperando un total de 212 registros. La distribución por base de datos fue: 128 documentos provenientes de Scopus, 30 de IEEE Xplore y 54 de Google Scholar (recuperados mediante búsqueda específica por título). Tras la identificación, se procedió a la detección de duplicados utilizando el gestor bibliográfico Zotero, eliminando 27 registros repetidos, lo que resultó en 185 documentos únicos para la fase de cribado.

2. Cribado (Screening) (Fase 2): Los 185 registros restantes fueron sometidos a un primer filtro basado en la lectura del título y resumen. En esta fase se aplicaron los criterios de inclusión generales (CI-1, CI-2 y CI-5), descartando un total de 121 artículos que no cumplieran con los requisitos básicos. Las exclusiones se desglosan de la siguiente manera:

- 30 documentos excluidos por antigüedad (publicados antes de 2020), en cumplimiento del criterio CI-1.
- 91 documentos excluidos por irrelevancia temática o por tipo de documento inadecuado, aplicando los criterios CI-2 y CI-5.

3. Elegibilidad (Fase 3): Se recuperaron y evaluaron a texto completo los 64 artículos que superaron el cribado. En esta etapa se aplicó un filtro técnico exhaustivo basado en los criterios de especificidad (CI-3, CI-4) y los criterios de exclusión (CE-1 a CE-4). Se excluyeron 42 estudios por las siguientes razones justificadas:

- 11 artículos se descartaron por falta de acceso al documento completo (CE-4), al no estar disponibles en las bases de datos institucionales ni en repositorios abiertos.
- 7 artículos se excluyeron por no cumplir con el criterio de datos estructurados (CI-3), al utilizar fuentes de datos no estructuradas

(imágenes, video o audio) no aplicables a tareas de clasificación en datos estructurados (CE-1).

- 24 artículos se eliminaron por no satisfacer el requisito de aporte técnico o metodológico (CI-4), al tratarse de enfoques puramente filosóficos, sociológicos o legales desvinculados del ciclo de vida del software, los cuales no aportan lineamientos de diseño, metodologías de aseguramiento de calidad ni requisitos técnicos aplicables a canalizaciones MLOps (CE-2).

4. Inclusión (Fase 4): Finalmente, 22 estudios cumplieron con la totalidad de los criterios de selección y fueron incluidos en la revisión sistemática. Estos documentos conforman la base para la extracción de datos y el análisis de la arquitectura propuesta en la presente tesis.

El flujo detallado de la selección y los motivos de exclusión se resumen en la **Figura 3** (Diagrama PRISMA).




Figura 3: Diagrama PRISMA

3.6 Formulario de extracción de datos

Para garantizar la consistencia en el análisis de la información, se diseñó un formulario de extracción que permite estandarizar los datos obtenidos de cada estudio seleccionado. Este instrumento facilita la posterior síntesis y

comparación de las arquitecturas *MLOps* y métodos de validación de equidad hallados.

Por consiguiente, se presentan los campos a recopilar en la Tabla 9.

Campo	Descripción
ID	Identificador único asignado al documento en tu base de datos.
Título	Título completo del documento.
DOI	Identificador de Objeto Digital.
Autor(es)	Autores a los que se les atribuye el estudio.
Año	Año de publicación del estudio.
Idioma	Idioma en el que el documento está redactado.
Objetivo Principal	El propósito central del artículo
Categoría de Sesgo	La clasificación formal del riesgo o sesgo que el artículo intenta resolver, basándote en la taxonomía del NIST.

Objetivo de Equidad	La meta matemática u organizacional de equidad que persigue el estudio.
Etapas de Intervención de Equidad	El momento exacto en el que el algoritmo o método mitiga el sesgo en el flujo de los datos o el modelo.
Métricas de Equidad y Trade-Offs	Qué métricas específicas de sesgo se utilizaron como prueba de calidad y cuánto rendimiento predictivo se sacrificó a cambio
Etapas del Pipeline	En qué fase del ciclo de vida de Machine Learning opera la herramienta o solución propuesta.
Stack Tecnológico / Herramientas MLOps	Las tecnologías, lenguajes o infraestructura de nube que posibilitan la automatización o el monitoreo de la arquitectura.
Hallazgos Clave	Los principales resultados comprobados empíricamente tras aplicar la técnica de equidad o la arquitectura MLOps.
Limitaciones / Brechas	Los problemas no resueltos por el estudio.

Tabla 9 Formulario de extracción

La aplicación detallada de este formulario y el almacenamiento de los metadatos de los artículos hallados se encuentran documentados en el repositorio digital de anexos de la investigación: **Anexo A**.

3.6 Resultados de revisión

3.6.1 Respuesta a Pregunta de Revisión 1

Los procesos tradicionales de validación de modelos de aprendizaje automático enfrentan severas ineficiencias estructurales que limitan la detección y mitigación efectiva de sesgos algorítmicos. En primer lugar, gran parte de la industria opera bajo un nivel de madurez tecnológico denominado "Nivel 0 de *MLOps*", el cual se caracteriza por ser un proceso manual, interactivo y profundamente desconectado de las operaciones de ingeniería de software (Kazmierczak et al., 2024). En este esquema, la validación de equidad suele replegarse a las etapas finales previas al despliegue. Al respecto, Vasquez et al. (2023) señalan que la falta de un enfoque proactivo en las fases iniciales del desarrollo impide intervenciones oportunas, lo que provoca la amplificación del sesgo a lo largo de la canalización e incrementa drásticamente la complejidad técnica para mitigarlo en etapas posteriores.

Aunado a la detección tardía, las auditorías tradicionales suelen evaluar el rendimiento y la equidad de la canalización de manera global, tratándola como un sistema opaco o de "caja negra" (Avuthu, 2021). Sin embargo, estudios recientes demuestran que este enfoque es ineficiente debido a que ignora la naturaleza composicional de la equidad; es decir, invisibiliza los sesgos que son inyectados de forma silenciosa por transformadores de datos individuales durante la etapa de preprocesamiento, tales como los imputadores o los escaladores (Biswas & Rajan, 2021). En consecuencia, esta falta de verificación modular impide a los desarrolladores y científicos de datos localizar el componente exacto que origina la discriminación, lo que dificulta significativamente el diagnóstico y la reparación del defecto algorítmico (Nguyen, 2024).

Finalmente, la validación estática resulta insuficiente frente al comportamiento dinámico de los entornos de producción, derivando en problemas de mantenimiento y cumplimiento normativo. Los datos del mundo real cambian constantemente y, si un modelo no es monitoreado de forma continua, puede

comenzar a producir resultados que reflejan sesgos emergentes de manera inadvertida, un fenómeno conocido como deriva del sesgo (Avuthu, 2021; IBM, s.f.; Reda et al., 2025). A esta ineficiencia operativa se suma la incapacidad de los procesos manuales para generar documentación trazable orientada al aseguramiento continuo de la calidad, lo cual es hoy una exigencia legal de la ingeniería de software para IA (Wagner, 2024). Sin una infraestructura que registre a nivel granular (semántico) el ciclo de vida del modelo, resulta inviable generar artefactos documentales que evidencien de manera transparente cómo se originó y mitigó el sesgo, erosionando la confianza institucional y bloqueando la capacidad de ejecutar auditorías efectivas (Russo & Vidal, 2025; Russo et al., 2024).

3.6.2 Respuesta a Pregunta de Revisión 2

Para superar las limitaciones de los enfoques tradicionales de "caja negra", las arquitecturas modernas se basan en la automatización de la integración y entrega continua (Nivel 2 de *MLOps*), donde la validación de equidad se incorpora como una prueba de calidad estructural desde las primeras fases del desarrollo (Kazmierczak et al., 2024). En este nivel, destacan herramientas como *ArgusEyes*, la cual facilita la detección proactiva al inspeccionar las canalizaciones de código durante la integración continua y detener automáticamente el proceso de compilación (*fail the build*) si se vulneran los umbrales de equidad preestablecidos (Schelter et al., 2023). Esta postura preventiva se complementa con marcos de pruebas de estrés como *Savage*, que inyectan corrupciones adversarias de datos para evaluar sistemáticamente las vulnerabilidades del modelo antes de su paso a producción (Zhu et al., 2025), y con sistemas híbridos como *HAMF*, que integran pasos de auditoría ética para computar y alertar sobre disparidades estadísticas de forma automatizada (Reda et al., 2025).

A diferencia de la evaluación global que oculta el sesgo inyectado por componentes individuales, los nuevos patrones de diseño promueven una evaluación estrictamente modular del código. En este sentido, investigaciones recientes proponen evaluar el preprocesamiento mediante razonamiento causal, comparando las predicciones de la canalización original frente a una variante que excluye un transformador de datos específico (como un escalador o un imputador), logrando así aislar el módulo exacto que está causando la discriminación (Biswas & Rajan, 2021). Para operativizar esta modularidad, se

ha propuesto el uso de "Contratos de Equidad", un patrón que adapta el Diseño por Contrato (*Design by Contract*) de la ingeniería de software al aprendizaje automático, permitiendo a los desarrolladores insertar anotaciones o decoradores directamente en el código para verificar precondiciones y postcondiciones de equidad a través de desigualdades de concentración (Nguyen, 2024). Adicionalmente, herramientas instrumentales como *mlwhatify* y *mlinspect* facilitan la depuración de la distribución de datos y el análisis declarativo tipo "qué pasaría si", permitiendo a los científicos de datos evaluar visualmente el impacto de distintas opciones de limpieza sobre la equidad sin la necesidad de reejecutar costosamente toda la canalización de manera repetida (Grafberger et al., 2022; Grafberger et al., 2023).

3.6.3 Respuesta a Pregunta de Revisión 3

En las arquitecturas MLOps modernas, el control de calidad (*QA*) se implementa mediante compuertas de calidad estrictas durante la fase de Integración y Entrega Continua (*CI/CD*) para bloquear el paso de modelos defectuosos. Un mecanismo destacado es la implementación de "Contratos de Equidad" (*Fairness Contracts*), los cuales adaptan el paradigma de diseño por contrato al aprendizaje automático mediante el uso de anotaciones que verifican precondiciones y postcondiciones modulares directamente en el código (Nguyen et al., 2025). Si un componente específico del *pipeline* viola una aserción de equidad en tiempo de ejecución, el sistema interrumpe automáticamente la ejecución (aborta el programa), impidiendo el despliegue del modelo sesgado y facilitando la localización exacta de la raíz del problema (Nguyen et al., 2025). Este escrutinio proactivo de *CI/CD* se complementa con herramientas de inspección como ArgusEyes, que detectan fugas de datos o problemas de etiquetado (Schelter et al., 2023). Asimismo, se aplican marcos de pruebas de estrés, como Savage, que inyectan corrupciones adversarias estructuradas en los datos (como valores faltantes o sesgos de selección) para evaluar sistemáticamente las vulnerabilidades del *pipeline* antes de su certificación operativa (Zhu et al., 2025).

Una vez que el modelo supera estas compuertas y es desplegado, la arquitectura MLOps requiere de un monitoreo continuo en producción para mitigar la degradación del rendimiento algorítmico en el mundo real, en particular la deriva del sesgo o *bias drift* (Avuthu, 2021; IBM, s.f.). Sistemas a nivel de

infraestructura, como Amazon SageMaker Model Monitor, abordan este desafío recopilando de manera automatizada los datos de las solicitudes de inferencia de los clientes y comparándolos contra líneas base (*baselines*) o restricciones calculadas durante el entrenamiento, lo que permite generar informes y alertar sobre violaciones de equidad (Amazon Web Services, 2022). A un nivel más avanzado (Nivel 2 de MLOps), marcos híbridos como HAMF (Hybrid MLOps Framework) cierran el ciclo implementando un Módulo de Cumplimiento Ético integrado a los procesos de reentrenamiento (Reda et al., 2025). Ante un cambio en las condiciones del entorno, HAMF no solo detecta la deriva, sino que aplica estrategias de adaptación como la sustitución de características inestables guiada por explicabilidad (SHAP), garantizando de forma comprobable que los modelos reentrenados de forma automatizada no introduzcan discriminación contra grupos protegidos (Reda et al., 2025).

3.6.4 Respuesta a Pregunta de Revisión 4

La integración de herramientas de validación de equidad en canalizaciones *MLOps* empresariales enfrenta significativos desafíos técnicos y de interoperabilidad. En la práctica, los ecosistemas de aprendizaje automático están compuestos por múltiples transformadores de datos y algoritmos que a menudo operan como "cajas negras", lo que dificulta la extracción y comunicación de métricas de equidad a través de las distintas fases del desarrollo y despliegue (Avuthu, 2021). Las herramientas tradicionales de mitigación y evaluación de sesgos suelen estar fragmentadas, careciendo de vocabularios estandarizados o formatos interoperables para compartir resultados a lo largo del ciclo de vida del modelo (Russo & Vidal, 2025). Esta heterogeneidad técnica complica el aseguramiento continuo de la calidad (*QA*), ya que implementar controles en infraestructuras nativas de la nube exige que los módulos de monitoreo operen integrados en tiempo real sin sobrecargar el sistema ni degradar la latencia de las inferencias (Avuthu, 2021; Biswas & Rajan, 2021).

Para superar estas barreras y cumplir con marcos de gobernanza estrictos —como la Ley de IA a nivel internacional (Wagner, 2024) y las recientes exigencias de auditoría para sistemas de riesgo alto en el Perú (Presidencia del Consejo de Ministros [PCM], 2025)—, las arquitecturas modernas abordan este problema mediante la implementación de la trazabilidad semántica. Utilizando sistemas neurosimbólicos y marcos basados en ontologías, como *InterpretME* y

Doc-BiasO, es posible capturar a nivel granular el linaje de los datos, los parámetros de preprocesamiento y las métricas de sesgo calculadas, estructurando toda esta información en Grafos de Conocimiento (Russo & Vidal, 2025; Russo et al., 2024). Esta representación enriquece semánticamente los metadatos en cada etapa de la canalización, generando un registro estandarizado que es comprensible tanto para sistemas automatizados como para auditores humanos (Russo et al., 2024). De este modo, las empresas logran traducir métricas matemáticas complejas en documentación probatoria y auditable, un requisito indispensable para ejecutar una correcta Gestión de Riesgos de Modelos (MRM) y garantizar la transparencia legal y ética de la IA en producción (IBM, s.f.; PCM, 2025).

3.7 Conclusiones del Estado del Arte

La revisión sistemática de la literatura desarrollada en este capítulo, ejecutada bajo la metodología PRISMA sobre bases de datos de alto impacto (*Scopus*, *IEEE Xplore* y *Google Académico*), permitió consolidar una selección final de 22 estudios primarios altamente relevantes para la investigación. El análisis de estos documentos evidencia una transición crítica en la ingeniería de software para IA, revelando explícitamente tres limitaciones operativas y arquitectónicas principales en los enfoques actuales:

1. **El enfoque de "caja negra" y la validación manual tardía (Limitación operativa):** Los procesos tradicionales de validación de modelos tratan al sistema como un bloque monolítico y postergan las auditorías hasta las fases previas al despliegue. Esta desconexión los hace inefficientes para detectar sesgos de naturaleza composicional (aquellos inyectados silenciosamente en etapas intermedias, como el preprocesamiento).
2. **Vulnerabilidad ante la deriva del sesgo o *bias drift* (Limitación arquitectónica):** Los enfoques clásicos carecen de controles continuos automatizados dentro del flujo de trabajo, lo que deja a los modelos desprotegidos y altamente vulnerables a adquirir nuevos sesgos una vez que operan con datos dinámicos en producción.
3. **Fragmentación de herramientas y falta de trazabilidad (Limitación tecnológica y operativa):** Las herramientas de auditoría tradicionales se encuentran aisladas y carecen de interoperabilidad. Esta desconexión

técnica imposibilita la creación de una trazabilidad semántica estructurada para los artefactos de aprendizaje automático, dificultando enormemente la generación de la documentación auditable que exigen los reguladores.

Para superar estas deficiencias estructurales, el estado del arte resalta la necesidad de adoptar arquitecturas *MLOps* modernas fundamentadas en la integración y entrega continua (*CI/CD*), las cuales incorporan la evaluación de equidad de manera modular y desde las etapas más tempranas. La literatura demuestra que la implementación de compuertas de calidad automatizadas es la estrategia más efectiva para un control proactivo. El uso de mecanismos como Contratos de Equidad, herramientas de inspección durante la compilación (como ArgusEyes) y marcos de pruebas de estrés (como Savage) permite interrumpir automáticamente las canalizaciones al detectar vulnerabilidades, bloqueando el despliegue de modelos discriminatorios antes de que lleguen a los usuarios finales.

Asimismo, para hacer frente al desafío de la interoperabilidad, la integración de ontologías (como Doc-BiasO) y Grafos de Conocimiento se ha posicionado como la solución tecnológica idónea para estructurar el linaje de los datos y generar la documentación auditable necesaria. Esta infraestructura documental no solo facilita la depuración técnica, sino que se ha convertido en un requisito legal ineludible frente a normativas recientes, como la Ley de IA de la Unión Europea y el Decreto Supremo N° 115-2025-PCM (Reglamento de la Ley N° 31814) en el Perú, que exigen transparencia y rendición de cuentas para los sistemas de alto riesgo.

En conclusión, los hallazgos de esta revisión sistemática validan de forma contundente la pertinencia tecnológica y regulatoria de la arquitectura propuesta en esta tesis. Al diseñar una solución *MLOps* que integra compuertas de calidad (*QA Gates*) automatizadas para la evaluación continua de la equidad, respaldada por un modelo conceptual de trazabilidad semántica, esta investigación cerrará las brechas operativas identificadas en la literatura y habilitará un ecosistema de despliegue de software confiable, justo y alineado con las normativas éticas y legales vigentes.

Capítulo 4: Diseño de la propuesta de solución

4.1 Introducción

El presente capítulo expone de manera formal el desarrollo metodológico y los productos de ingeniería correspondientes al Objetivo Específico O2 de esta investigación, el cual consiste en: *"Diseñar el esquema de la arquitectura MLOps local que integre compuertas de calidad (QA Gates) modulares y un modelo semántico para garantizar la trazabilidad ética en todas las etapas del pipeline de scoring crediticio"*.

En las organizaciones de tecnología financiera (*Fintech*), el aseguramiento de la equidad se ha abordado históricamente mediante auditorías estáticas, desarticuladas y tardías sobre el modelo final, asumiendo una concepción monolítica del pipeline de Machine Learning. Este enfoque convencional impide localizar con precisión qué transformador de software o lote de datos específico inyectó la desviación discriminatoria, elevando exponencialmente los costos operativos de depuración y exponiendo a las entidades a severas sanciones legales bajo marcos regulatorios financieros internacionales como la *Equal Credit Opportunity Act* (ECOA) de Estados Unidos o el Reglamento de IA de la Unión Europea.

Para resolver esta problemática de forma proactiva, este capítulo detalla la concepción lógica y abstracta de una arquitectura de software ética por diseño. En estricta concordancia con las directrices de diseño metodológico, las secciones siguientes se estructuran para describir y verificar de manera transparente los tres resultados esperados: en primer lugar, el esquema general del sistema modelado bajo el Modelo C4 (R.E.2.1) que define las cuatro zonas locales y la ubicación estratégica de las tres compuertas de calidad (*QA Gates*); en segundo lugar, la especificación y formulación matemática de los Contratos de Equidad (R.E.2.2) aplicados de forma modular en el pipeline de crédito; y, en tercer lugar, el modelo conceptual de la Ontología OWL de Fairness (R.E.2.3) diseñado para estructurar el linaje inmutable de las decisiones del clasificador crediticio. Finalmente, se presenta una sección de discusión crítica orientada a interpretar el valor científico del diseño, contextualizar su consistencia frente a la literatura de MLOps de Nivel 2 y declarar con transparencia sus alcances y limitaciones.

4.2 Esquema arquitectónico detallado (Modelo C4) y flujos CI/CD

4.2.1. Descripción del resultado alcanzado

El primer resultado alcanzado consiste en el diseño formal de la topología física y lógica de la solución, denominada "Sistema MLOps Fairness QA". Para representar de manera clara los flujos de automatización e integración continua sin nube (local), la arquitectura se ha modelado utilizando el enfoque de diagramación estructurada Modelo C4, dividiéndose en tres niveles de abstracción:

Nivel 1: Diagrama de Contexto: En el nivel más alto de abstracción, el sistema principal interactúa con dos usuarios clave y dos sistemas externos. El **Científico de Datos** es el encargado de configurar y ejecutar el código fuente del *pipeline*, mientras que el **Auditor del Sistema** consulta y genera reportes con visualizaciones de explicabilidad para garantizar el cumplimiento ético. El sistema recibe información de una **Fuente de Datos** externa (que provee datos tabulares estructurados) y es gestionado por un **orquestador de CI/CD** externo, el cual gestiona el código fuente y dispara los eventos de integración y entrega continua (*triggers*).




Figura 4: Diagrama de Contexto

Nivel 2: Diagrama de Contenedores: El sistema descompone su flujo en cuatro grandes contenedores operativos, denominados "Zonas", que aíslan los entornos de ejecución y una capa de trazabilidad semántica:

- **Zona 1 (Ingesta, preprocesamiento y validación de datos):** Un contenedor de *pipeline* de datos impulsado por Python, Pandas, Pandera y DVC.
- **Zona 2 (CI y Entrenamiento):** Un contenedor de *pipeline* de Machine Learning que utiliza Scikit-learn para el modelado y herramientas como Pytest, AIF360 y Fairlearn para la evaluación técnica y ética.
- **Zona 3 (CD y Monitoreo Continuo):** Un contenedor de servicio y monitoreo (*Serving + Monitor*) orquestado por GitHub Actions, MLflow y Evidently AI para supervisar la telemetría y detectar posibles derivas.
- **Zona 4 (Trazabilidad semántica y auditoría):** Un contenedor basado en Grafos de Conocimiento (Knowledge Graph) orquestado con InterpretME, RDFLib, OWL, GraphDB y SPARQL.
- **Canal de Linaje — MLflow (Tracking & Registry):** Contenedor transversal que actúa como bus de integración semántica entre todas las zonas del sistema. Las Zonas 1, 2 y 3 escriben continuamente en él sus metadatos de ejecución: procedencia de datos, hiperparámetros, resultados de las compuertas de calidad, métricas de equidad, valores de explicabilidad y telemetría de producción. La Zona 4 lo consume como única fuente de entrada para construir el Grafo de Conocimiento. Su rol no se limita al tracking de experimentos convencional: en esta arquitectura constituye el único punto de acoplamiento entre el pipeline de Machine Learning y la capa de trazabilidad semántica, garantizando que ningún evento del sistema quede sin registro auditable.




Figura 5: Diagrama de contenedores

Nivel 3: Diagrama de Componentes y Flujos CI/CD: Este nivel detalla el comportamiento interno de las Zonas y define la ubicación estratégica de las Compuertas de Calidad (*QA Gates*) y los flujos de interrupción:

- Zona 1 (Preprocesamiento):** El flujo inicia cuando el componente "Ingestor de datos" carga y versiona los lotes crudos. Posteriormente, el "Validador de esquema" y el "Detector de sesgo temprano" examinan la información antes de aplicar la **QA Gate 1 (Contrato de equidad para datos crudos)**. Esta compuerta, instrumentada con Pytest y Pandera, evalúa el sesgo de esquema, de valores y la representación mínima de los grupos protegidos. Si el lote pasa, es procesado por "Transformadores modulares" (ej. *encoding, scaling, imputation*), tras lo cual un "Evaluador de impacto ético" de Fairlearn compara la distribución pre y post transformación. Aquí actúa la **QA Gate 2 (Contrato post-transformación)**; si se detecta inyección de sesgo por los transformadores, el *pipeline* falla inmediatamente (abortando el *run* y registrándolo en el grafo). Si es exitoso, los artefactos se versionan en el *Feature Store* mediante DVC.




Figura 6: Diagrama de componentes de la Zona 1

- Zona 2 (CI y Entrenamiento):** Al activarse el *Trigger CI*, el "Cargador de features" extrae la versión fijada en DVC y el "Entrenador de modelo" de Scikit-learn realiza el ajuste supervisado. Seguidamente, un "Módulo de stress testing" y un "Evaluador de disparidad" (AIF360 + Fairlearn) calculan métricas como DPD (*Demographic Parity Difference*) y EOD (*Equal Opportunity Difference*). Estos resultados son evaluados por la **QA Gate 3 (Contrato de equidad del modelo)**, configurado mediante un archivo YAML que declara umbrales de tolerancia por métrica y grupo protegido. Si los umbrales se violan, se notifica el fallo y se interrumpe el despliegue. Si pasa la compuerta, el componente generador de

explicabilidad (SHAP) extrae la importancia de las *features*, MLflow registra el experimento y se aprueba la versión segura del modelo.




Figura 7: Diagrama de componentes de la Zona 2

- Zona 3 (CD y Producción):** Con la versión aprobada, el *Trigger CD* activa al "Desplegador del proyecto", colocando el modelo en un "Endpoint de inferencia". Un componente de "Captura y anonimización" registra las predicciones en vivo protegiendo atributos sensibles. Simultáneamente, Evidently AI actúa como "Monitor de data drift" y "Monitor de bias drift", realizando auditoría ética continua. Si el "Decisor de reentrenamiento" detecta que el rendimiento o la equidad se han degradado, el "Generador de alertas" notifica las anomalías y dispara un reentrenamiento continuo de vuelta hacia la Zona 1.




Figura 8: Diagrama de componentes de la Zona 3

- Zona 4 (Trazabilidad Semántica):** De manera paralela, un "Extractor de linaje" consume las APIs de MLflow e InterpretME junto con las métricas locales de SHAP. Utilizando una "Ontología OWL de Fairness", el "Constructor de triples RDF" serializa todos los metadatos generados por las *QA Gates*. Estos se almacenan en la base de datos "GraphDB", que soporta razonamiento inferencial y permite que un "Motor de consulta semántica" (SPARQL) genere los reportes de cumplimiento y las visualizaciones de forma automatizada para la revisión del Auditor.




Figura 9: Diagrama de componentes de la Zona 4

4.2.2 Metodología de logro y reproducibilidad

Para alcanzar y estructurar este resultado de diseño, se emplearon las metodologías de **Ingeniería de Software Orientada a Arquitecturas** descritas en el Capítulo 1, siguiendo un proceso iterativo de cuatro pasos para asegurar su reproducibilidad:

1. **Identificación de fronteras de datos y seguridad:** Se estableció como restricción de diseño que el 100% de los contenedores lógicos debían operar en un entorno local desconectado de internet para cumplir con la confidencialidad bancaria y evitar dependencias de APIs en la nube.
2. **Delimitación de Zonas operativas:** Se aplicó el principio de separación de preocupaciones (*separation of concerns*) para segmentar el ciclo de vida del scoring crediticio en las cuatro Zonas descritas en el Modelo C4,

aislando el preprocesamiento de datos del entrenamiento del modelo y el monitoreo en vivo de la base de conocimiento semántica.

3. **Modelado visual bajo el estándar C4:** Utilizando la herramienta de diagramación Lucidchart, se construyeron de forma secuencial las abstracciones de Contexto, Contenedores y Componentes, etiquetando los protocolos de comunicación interna (archivos locales, aserciones en tiempo de compilación y llamadas de API internas REST).
4. **Validación del flujo de automatización (CI/CD/CT):** Se mapearon conceptualmente los disparadores (*triggers*) lógicos de control de versiones. Se diseñó el flujo para que cualquier cambio de código o datos dispare un *Trigger CI* en la Zona 2, y que el decaimiento de equidad en la Zona 3 dispare un reentrenamiento (*Trigger CT*) de retorno hacia la Zona 1, cerrando el ciclo de vida automatizado del software de scoring crediticio.

4.2.3. Verificación de existencia

La existencia física de este diseño arquitectónico se verifica a través del Diagrama arquitectónico y documento de diseño técnico de la solución, consolidado en la presente tesis. Las especificaciones visuales de este entregable están representadas formalmente en los siguientes diagramas integrados en el sistema semántico de la tesis:

- **Figura 4 (Diagrama de Contexto - Nivel 1):** Presenta las fronteras lógicas y los actores del scoring crediticio local.
- **Figura 5 (Diagrama de Contenedores - Nivel 2):** Define la segregación de las cuatro Zonas operativas del pipeline MLOps.
- **Figura 6, 7 y 8 (Diagramas de Componentes - Nivel 3):** Detallan los flujos internos de componentes de software para la validación, entrenamiento y monitoreo continuo del sistema.

4.2.4 Mediciones y validación del indicador

El cumplimiento planificado para este entregable se valida cuantitativamente mediante su correspondencia con el Indicador del R.E.2.1 establecido en el Capítulo 1 de la tesis: *"Un diagrama arquitectónico que identifique explícitamente las cuatro (4) Zonas del pipeline local, la capa semántica superior y la ubicación exacta de las tres (3) compuertas de calidad (QA Gates) de equidad modulares"*.

La evaluación cualitativa de cobertura de diseño demuestra el cumplimiento de este indicador al verificar la existencia física de los siguientes componentes mapeados en el diagrama:

1. **Identificación de las 4 Zonas:** Zona 1 (Ingesta), Zona 2 (CI), Zona 3 (CD) y Zona 4 (Semántica) representadas con fronteras cerradas.
2. **Capa semántica superior:** Zona 4 diseñada como un almacén de conocimiento unificado acoplado asíncronamente con las Zonas 1, 2 y 3.
3. **Ubicación de las 3 QA Gates:**
 - **QA Gate 1 (Sesgo de Datos Crudos):** Diseñada al final de la Zona 1, justo después del validador de esquemas de Pandera y antes de la persistencia de datos.
 - **QA Gate 2 (Sesgo de Transformadores):** Ubicada en la Zona 1, posterior al componente de preprocesamiento, para detener flujos si las transformaciones inyectan sesgos por proxy.
 - **QA Gate 3 (Sesgo del Modelo):** Ubicada en la Zona 2 (CI), operando como la compuerta final del flujo de integración continua para evaluar el clasificador supervisado antes de habilitar su registro y entrega CD.

4.3 Especificación de diseño de los componentes modulares de validación de equidad

4.3.1. Descripción del resultado alcanzado

El segundo resultado consiste en la Especificación de Diseño de los componentes lógicos de validación, los cuales estructuran la lógica de control interna de las tres Compuertas de Calidad (*QA Gates*). A diferencia de las evaluaciones convencionales de equidad que operan de manera reactiva sobre el modelo predictivo final, esta especificación define un enfoque de control modular basado en el paradigma de Diseño por Contrato (DbC) (Nguyen, 2024; Nguyen et al., 2025).

Cada compuerta está diseñada como una función de aserción de calidad de software que recibe entradas específicas, evalúa condiciones lógicas o probabilísticas predefinidas y retorna un estado binario de validación (Pasa / Falla). Si el estado es Falla, el componente interrumpe inmediatamente la ejecución del pipeline con un código de error de sistema (exit 1 en el entorno de pruebas automatizadas), impidiendo la propagación del sesgo y el despliegue del software (Nguyen, 2024; Nguyen et al., 2025).

Contrato	Compuerta	Zona	Punto de Control	Naturaleza (DbC)
C1	QA Gate 1	Zona 1	Datos Crudos (antes de transformar)	Precondición del pipeline
C2	QA Gate 2	Zona 1	Datos post-transformación	Postcondición de los transformadores modulares
C3	QA Gate 3	Zona 2	Modelo entrenado	Postcondición del entrenamiento

Tabla 10: Contratos de Equidad

Para garantizar que los tres contratos sean auditables, versionables y desacoplados del código fuente de Machine Learning (evitando "umbrales mágicos" incrustados en el código), se define un esquema declarativo común en formato YAML. Este esquema es el artefacto que consume el framework de

pruebas automatizadas en tiempo de ejecución para materializar cada *QA Gate*, y es también el archivo que posteriormente la Zona 4 serializa como triples RDF para garantizar su trazabilidad semántica.

Campo	Tipo de dato	Descripción
contract_id	String	Identificador único del contrato (ej. C1-schema-crudo)
gate	String	Compuerta de calidad a la que pertenece (ej. QA_GATE_1)
stage	String	Etapas del pipeline donde se evalúa (ej. ingesta)
protected_attributes	List (String)	Lista de atributos protegidos evaluados (ej. sexo)
rules	List (Object)	Lista de reglas definidas por la triada: metric, operator y threshold .
on_violation.action	String	Acción ante violación de umbral: block (abortar) o warn (registra y continúa) .
tooling	String	Biblioteca de software responsable de calcular la métrica (Pandera, AIF360, Fairlearn).

Tabla 11: Esquema declarativo de un contrato

4.3.2. Metodología de logro y reproducibilidad

De conformidad con lo establecido en la Fase 2 (Diseño Arquitectónico y Formulación de Contratos) de la Sección 1.3.2 del Capítulo 1, este entregable se alcanzó mediante la articulación de la formulación estadística de equidad algorítmica y el paradigma de Diseño por Contrato (DbC) (Nguyen, 20 Nguyen et al., 2025). Los contratos y aserciones de software se estructuraron de manera declarativa en formato YAML y fueron especificados lógicamente para ser ejecutados de manera automatizada por el motor de pruebas Pytest y calculados mediante las bibliotecas especializadas Pandera, AIF360 y Fairlearn detalladas

en el stack de la Sección 1.3.1 del Capítulo 1, siguiendo un proceso riguroso de tres etapas:

- A. **Modelado matemático del scoring crediticio:** Se formalizó la tarea de clasificación binaria supervisada, definiendo el espacio de variables del deudor como un vector X , la etiqueta real de solvencia como $Y \in \{0, 1\}$ (donde 1 representa comportamiento de pago favorable y 0 representa default), y el atributo protegido demográfico sensible como $Z \in \{0, 1\}$ (donde $Z=0$ es el grupo no privilegiado y $Z=1$ es el grupo privilegiado) (MathWorks, s.f.).
- B. **Definición de aserciones de software para datos y transformadores:** Se diseñaron las precondiciones y postcondiciones del pipeline de datos para aislar la inyección composicional de desviaciones en la Zona 1 (preprocesamiento), operativizando las aserciones mediante aserciones de consistencia en el código (Biswas & Rajan, 2021; Nguyen, 2024).
- C. **Formulación matemática de aserciones de modelo:** Se seleccionaron e integraron en la postcondición de entrenamiento las fórmulas canónicas de equidad de grupo de Hardt, Price y Srebro (Hardt et al., 2016), configurando umbrales estrictos de tolerancia ética basados en la regla de los cuatro quintos de la jurisprudencia crediticia internacional (Bartlett et al., 2022).

4.3.3. Verificación de existencia

La existencia de este resultado se verifica a través del entregable físico denominado "Especificación técnica de componentes de Validación de Equidad", el cual se anexa como un documento técnico formal en la presente tesis. Este documento describe de manera precisa las firmas de las funciones, los datos de entrada requeridos en formato estructurado (esquemas) y la configuración de los archivos declarativos YAML.

A continuación, se detalla un ejemplo de instanciación del archivo de configuración declarativa del Contrato C3 (QA Gate 3) en formato YAML, el cual representa la plantilla técnica de validación del modelo entrenado en la Zona 2:

Java

```
contract_id: "C3-fairness-modelo"
gate: "QA_GATE_3"
stage: "modelo_entrenado"
protected_attributes:
  - "sexo"
  - "edad_agrupada"
rules:
  - metric: "demographic_parity_difference"
    operator: "le"
    threshold: 0.10
  - metric: "equal_opportunity_difference"
    operator: "le"
    threshold: 0.10
  - metric: "disparate_impact_ratio"
    operator: "ge"
    threshold: 0.80
on_violation:
  action: "block"
tooling: "AIF360"
```

4.3.4. Mediciones y validación del indicador

El cumplimiento del R.E.2.2 se valida al contrastarlo con su Indicador del R.E.2.2 declarado en el Capítulo 1: *"Formulación matemática explícita de las reglas, aserciones y umbrales tolerables de equidad e integridad de datos para las tres (3) compuertas de calidad (QA Gates) del pipeline"* (ver Tabla 3).

La especificación de diseño cumple con este indicador al formular matemáticamente los siguientes contratos de control de software:

Contrato C1: QA Gate 1 (Integridad y Representación en Datos Crudos)

- **Naturaleza:** Precondición de datos.

- **Integridad de datos:** Valida que el lote de entrada D_{raw} cumpla con el esquema, tipificación y restricciones lógicas estructurales:

$$\forall_c \in Columns(D_{raw}), Tipo(c) \in \mathcal{T}_{permitidos} \wedge Nulos(c) = 0$$

- **Sesgo de representación temprano:** Exige que la proporción de registros pertenecientes al subgrupo no privilegiado ($Z = 0$) respecto al total del lote supere el umbral mínimo $\mathcal{T}_{rep}$ (fijado en $\mathcal{T}_{rep} = 0.05$ o 5%):

$$P(Z = 0 \mid D_{raw}) \geq \mathcal{T}_{rep}$$

- **Interpretación:** Si cualquier registro vulnera la integridad o si el subgrupo sensible representa menos del 5% del lote, el contrato falla y el pipeline se detiene en la Zona 1 antes de alimentar los transformadores.

Contrato C2: QA Gate 2 (Aislamiento de Sesgo Composicional en Transformadores)

- **Naturaleza:** Postcondición de transformadores modulares (codificación, escalado e imputación).
- **Evaluación del impacto diferencial:** Evalúa la alteración introducida por la transformación contrastando la distribución pre y postratamiento, operativizando la naturaleza composicional del sesgo (Biswas & Rajan, 2021). Se calcula la información mutua condicional entre las variables transformadas X_{trans} y el atributo protegido Z , condicionado a la etiqueta real de riesgo Y , asegurando que permanezca por debajo del umbral $\mathcal{T}_{proxy}$ (fijado en 0.10):

$$I(X_{trans}; Z \mid Y) < \mathcal{T}_{proxy}$$

- **Interpretación:** Si un transformador (e.g., imputación de nulos mediante **SimpleImputer**) introduce dependencia espuria o altera la distribución del grupo protegido por encima del umbral respecto a su estado original, el contrato falla. Esto permite aislar y diagnosticar de forma modular el transformador responsable, evitando delegar la detección únicamente a la auditoría del modelo final.

Contrato C3: QA Gate 3 (Evaluación Ética del Modelo Predictivo Entrenado)

- **Naturaleza:** Postcondición del entrenamiento. Evalúa las predicciones $\hat{Y} = h(X)$ del estimador supervisado frente a criterios formales de equidad de grupo:

- **Diferencia de paridad demográfica (SPD):** Exige paridad en las tasas de aprobación entre grupos, admitiendo una desviación máxima $\epsilon_{SPD} = 0.10$:

$$|SPD| = |P(h(X) = 1 \mid Z = 0) - P(h(X) = 1 \mid Z = 1)| \leq \epsilon_{SPD}$$

- **Diferencia de igualdad de oportunidades (EOD):** Exige que la tasa de verdaderos positivos (TPR) sea equivalente entre subgrupos de deudores solventes ($Y = 1$), con una tolerancia máxima $\epsilon_{EOD} = 0.10$ (Hardt et al., 2016):

$$|EOD| = |P(h(X) = 1 \mid Y = 1, Z = 0) - P(h(X) = 1 \mid Y = 1, Z = 1)| \leq \epsilon_{EOD}$$

- **Impacto dispar (\$DIS):** Exige que la tasa de selección favorable relativa cumpla con la regla de los cuatro quintos para mitigar discriminación indirecta (Bartlett et al., 2022):

$$DI = \frac{P(h(X)=1|Z=0)}{P(h(X)=1|Z=1)} \geq 0.80$$

Mecanismo de Interrupción en Caliente (Común a C1, C2 y C3)

- Pytest carga dinámicamente en tiempo de ejecución las especificaciones declarativas desde el archivo YAML correspondiente.
- Ejecuta las aserciones lógicas contrastando las métricas empíricas computadas mediante AIF360 y Fairlearn.
- Si todas las condiciones se satisfacen, el pipeline continúa su ejecución.
- Si alguna condición se incumple y su directiva asociada es **block**, el proceso emite un código de salida **exit 1**. El orquestador de CI/CD aborta el despliegue del modelo, registra el fallo en el canal de linaje (MLflow) y los metadatos se serializan como tripletas RDF en la Zona 4 (R.E.2.3).

4.4. Modelo conceptual de trazabilidad y gobernanza semántica

4.4.1. Descripción del resultado alcanzado

El tercer resultado de ingeniería consiste en el diseño conceptual del Grafo de Conocimiento y el modelado lógico de la Ontología OWL de Fairness (Fairness Ontology). En un sistema de scoring crediticio de alto riesgo, no basta con localizar e interrumpir un pipeline sesgado; es un estricto imperativo legal bajo regulaciones como la ECOA de Estados Unidos y el reglamento de IA de la UE contar con una documentación auditable e inmutable sobre el linaje de datos (*provenance*) y las decisiones del clasificador.

La ontología diseñada representa un modelo conceptual semántico estructurado que unifica el vocabulario del sistema de software, permitiendo que tanto auditores humanos como agentes de software comprendan de forma unívoca el significado de los términos, los parámetros de entrenamiento, los valores locales de explicabilidad de características (valores SHAP) y los resultados de las aserciones de calidad de las *QA Gates* (Russo et al., 2024; Russo & Vidal, 2025).

Para caracterizar formalmente la estructura lógica del modelo y describir detalladamente el resultado alcanzado, la ontología unifica y reutiliza vocabularios semánticos del estándar W3C como PROV-O (para linaje), DCAT (para datasets), MLS (Machine Learning Schema) y DQV (Data Quality Vocabulary). A continuación, se detalla la Taxonomía de Clases (OWL Classes) diseñada para modelar de forma exhaustiva el dominio del scoring crediticio y la gobernanza MLOps:

Clase OWL	Descripción	Zona de origen	Vocabulario Base
fair:DataBatch	Representa un lote lógico de datos crudos procesado en el pipeline, identificado por su hash de versión DVC.	Zona 1	dcat:Dataset / prov:Entity
fair:Transformer	Mapa un transformador modular específico aplicado (encoding, scaling,	Zona 1	mls:Process

	imputación).		
fair:FairnessContract	Define las restricciones formales lógicas y probabilísticas de equidad (Contratos C1, C2 o C3)	Transversal	mls:Evaluation Procedure
fair:GateExecution	Registra la ejecución física e instantánea de un QA Gate sobre un batch o modelo con estado PASA/FALLA.	Zona 1,2	prov:Activity
fair:ProtectedAttribute	Atributo demográfico protegido evaluado (ej. sexo, edad agrupada)	Transversal	skos:Concept
fair:FairnessMetric	Representa la métrica calculada en tiempo de ejecución (schema_violation_count, DPD, EOD, etc.).	Zona1,2	mls:Evaluation Measure
fair:ModelVersion	Versión exacta del clasificador de riesgo crediticio entrenado y guardado en MLFlow.	Zona 2	mls:Model
fair:Explainability Record	Contenedor de metadatos de atribución local de características calculados vía SHAP.	Zona 2	prov:Entity
fair:DeploymentEvent	Evento físico de despliegue o bloqueo del modelo en producción.	Zona 3	prov:Activity
fair:DriftObservation	Captura la observación de data drift o bias drift registrada en vivo por el monitor.	Zona 3	prov: Entity
fair:ComplianceReport	Artefacto documental autogenerado para auditorías de cumplimiento	Zona 4	foaf:Document / prov:Entity

Tabla 12: Definición de la Taxonomía de Clases

4.4.2. Metodología de logro y reproducibilidad

De conformidad con las especificaciones de la Fase 2 (Diseño Arquitectónico y Formulación de Contratos) de la Sección 1.3.2, el modelado conceptual del Grafo de Trazabilidad se fundamentó en la metodología de Ingeniería Ontológica de Noy y McGuinness, articulando de forma directa el uso de las especificaciones W3C RDF y OWL, junto con las herramientas InterpretME, RDFLib y GraphDB declaradas en el stack de la Sección 1.3.1 del Capítulo 1 (y anticipando el flujo de recolección de metadatos de la Fase 4 de la Sección 1.3.2 del Capítulo 1). Este proceso de diseño y estructuración de la ontología de equidad se ejecutó siguiendo un flujo metodológico de cuatro pasos esenciales para asegurar su reproducibilidad técnica y semántica:

- **Determinación del alcance y competencia:** Se formularon preguntas de competencia en lenguaje SPARQL para guiar el diseño conceptual (ej. *"¿Qué ejecuciones del QA Gate fallaron por sesgo en el atributo sexo en el último mes, y bajo qué contrato?"*).
- **Enumeración de términos y jerarquía de clases:** Se identificaron e integraron los vocabularios y estándares semánticos del World Wide Web Consortium (W3C), como las especificaciones RDF y la ontología PROV-O de linaje de datos (Russo et al., 2024).
- **Definición de propiedades y restricciones:** Se definieron las relaciones conceptuales entre entidades (*Object Properties*) y las características de atributos numéricos de las mediciones (*Data Properties*).
- **Validación semántica:** Se documentaron las clases y relaciones conceptuales para garantizar la consistencia lógica de la ontología OWL resultante, preparándola para su posterior instanciación en triples factuales.

Para asegurar la reproducibilidad de la metodología y comprobar si la ontología diseñada es capaz de responder a sus preguntas de competencia, se simuló su validación de consistencia formulando la siguiente consulta SPARQL declarativa. Esta consulta es la que ejecutará de manera automatizada el Auditor del Sistema en GraphDB (Zona 4) para extraer las evidencias técnicas de fallos en el QA Gate 1 o QA Gate 3 asociados con sesgos en el atributo sexo durante las ejecuciones mensuales del software:

SQL

```
PREFIX fair: <https://pucp.edu.pe/ontology/fair#>
PREFIX prov: <http://www.w3.org/ns/prov#>
PREFIX xsd: <http://www.w3.org/2001/XMLSchema#>

SELECT ?executionRun ?contractId ?datasetHash ?calculatedValue ?thresholdValue
?timestamp
WHERE {
    # 1. Recuperar ejecuciones de compuertas de calidad fallidas
    ?executionRun a fair:GateExecution ;
                  fair:isGatePassed false ;
                  fair:appliesContract ?contract ;
                  fair:evaluatedBy ?dataset ;
                  prov:startedAtTime ?timestamp .

    # 2. Obtener el detalle del contrato que falló
    ?contract fair:contractId ?contractId ;
              fair:concernsAttribute ?attribute ;
              fair:hasThreshold ?thresholdValue .

    # 3. Filtrar específicamente por el atributo protegido de género o sexo
    ?attribute fair:attributeName "sexo" .

    # 4. Obtener el hash del conjunto de datos evaluado
    ?dataset fair:hasDvcHash ?datasetHash .

    # 5. Obtener las métricas que provocaron la interrupción
    ?executionRun fair:producesMetric ?metric .
    ?metric fair:hasMetricValue ?calculatedValue .

    # 6. Filtrar por ejecuciones ocurridas en el último mes (simulado para
    Agosto 2026)
    FILTER(?timestamp >= "2026-07-25T00:00:00Z"^^xsd:dateTime)
}
ORDER BY DESC(?timestamp)
```

La resolución exitosa de esta consulta SPARQL permite extraer del Grafo de Trazabilidad una evidencia técnica e inmutable sobre el fallo del pipeline en tiempo de compilación. Esta información es la que consume el componente generador de reportes de la Zona 4 para compilar el Compliance Report final en PDF, cerrando de forma conceptual y metodológica el ciclo de aseguramiento de calidad y auditalibilidad semántica (Russo et al., 2024).

4.4.3. Verificación de existencia

La existencia de este resultado se verifica a través del Esquema del modelo semántico de trazabilidad ética, el cual se anexa formalmente como un archivo de modelado de ontología serializado en formato de sintaxis Turtle en la presente tesis. Este esquema proporciona la base lógica para que el repositorio RDF local (GraphDB) realice deducciones lógicas y responda a consultas complejas de auditoría.

Para materializar y verificar físicamente la existencia del grafo de conocimiento diseñado, se detalla a continuación una instanciación conceptual en sintaxis Turtle de una ejecución fallida del QA Gate 1 (Contrato C1) sobre un lote de datos de *German Credit*. Este fragmento demuestra que el diseño tiene existencia física real como una base de conocimiento serializable, legible y estructurada semánticamente:

SQL

```
@prefix fair: <https://pucp.edu.pe/ontology/fair#> .
@prefix prov: <http://www.w3.org/ns/prov#> .
@prefix dcat: <http://www.w3.org/ns/dcat#> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .

# 1. Instanciación del lote de datos crudo versionado en DVC
fair:DataBatch_GermanCredit_v1
  a fair:DataBatch , dcat:Dataset ;
  fair:hasDvcHash "9dd7e9aad1854f97b3c9e3526b44d783" ;
  fair:recordsCount 1000 ;
  prov:startedAtTime "2026-08-18T04:14:00Z"^^xsd:dateTime .

# 2. Instanciación del Contrato de Equidad C1
fair:Contract_C1_Representatividad
  a fair:FairnessContract ;
  fair:contractId "C1-schema-crudo" ;
  fair:concernsAttribute fair:Attribute_Sexo ;
  fair:hasThreshold "0.05"^^xsd:float .

# 3. Registro del Atributo Protegido
fair:Attribute_Sexo
  a fair:ProtectedAttribute ;
  fair:attributeName "sexo" ;
  fair:unprivilegedValue "female" .

# 4. Instanciación de la Ejecución fallida de la Compuerta en CI (QA Gate 1)
```

```

fair:GateExecution_Run_4591
  a fair:GateExecution , prov:Activity ;
  fair:appliesContract fair:Contract_C1_Representatividad ;
  fair:evaluatedBy fair:DataBatch_GermanCredit_v1 ;
  fair:isGatePassed "false"^^xsd:boolean ;
  fair:hasGateResult "FALLA" ;
  fair:producesMetric fair:Metric_Representacion_Sexo ;
  prov:wasAssociatedWith fair:SoftwareAgent_PanderaValidator .

# 5. Mapeo de la métrica resultante que causó el fallo
fair:Metric_Representacion_Sexo
  a fair:FairnessMetric ;
  fair:metricName "proportion_unprivileged" ;
  fair:hasMetricValue "0.032"^^xsd:float . # 3.2% (viola el umbral de 5%)

```

4.4.4. Mediciones y validación de indicador

El cumplimiento del entregable se valida mediante su correspondencia con el Indicador del R.E.2.3 establecido en el Capítulo 1: *"Ontología semántica formal documentada que interconecte las entidades de datos de crédito, parámetros de entrenamiento, resultados de las QA Gates y métricas calculadas de explicabilidad"*.

La ontología diseñada cumple de manera sobresaliente con este indicador al definir y documentar de manera formal las relaciones semánticas entre entidades. Mientras que las clases (OWL Classes) establecen la taxonomía de datos, la verdadera interconexión exigida por el indicador se define a través de las Propiedades de Objeto (OWL Object Properties) y Propiedades de Datos (OWL Data Properties), las cuales articulan el grafo en una red lógica unificada de conocimiento:

Propiedad	Dominio → Rango	Significado
fair:derivedFrom	fair:Transformer → fair:DataBatch	El transformador modular se aplicó sobre este lote de datos
fair:evaluatedBy	fair:DataBatch/	Identifica qué ejecución

	fair:ModelVersion → fair:GateExecution	de compuerta evaluó el dataset o el modelo.
fair:appliesContract	fair:GateExecution → fair:FairnessContract	Define bajo qué contrato de equidad se ejecutó la validación.
fair:concernsAttribute	fair:FairnessContract → fair:ProtectedAttribute	Vincula el contrato con el atributo demográfico protegido sensible evaluado.
fair:producesMetric	fair:GateExecution → fair:FairnessMetric	Relaciona la ejecución con las métricas cuantitativas resultantes.
fair:hasOutcome	fair:GateExecution → {Pasa, Falla}	Registra el resultado lógico de la evaluación del contrato de equidad
fair:trainedInto	fair:DataBatch → fair:ModelVersion	Mapea el lote de datos exacto utilizado para ajustar el modelo.
fair:explainedBy	fair:ModelVersion → fair:ExplainabilityRecord	Vincula el clasificador entrenado con su registro de SHAP.
fair:deployedAs	fair:ModelVersion → fair:DeploymentEvent	Mapea el evento de despliegue físico derivado de la aprobación del modelo.
fair:monitoredBy	fair:DeploymentEvent → fair:DriftObservation	Asocia el despliegue con las observaciones de drift recopiladas en vivo.
fair:documentedIn	fair:GateExecution \ fair:DriftObservation → fair:ComplianceReport	Asocia los hechos técnicos y los fallos con el reporte final PDF de cumplimiento

Tabla 13: Relaciones Principales (OWL)

Para asegurar que la interconexión no sea solo estructural sino también métrica y cuantitativa, se diseñaron propiedades de datos que asocian valores literales a los nodos del grafo:

- **fair:hasMetricValue** (Dominio: **fair:FairnessMetric** o Rango: **xsd:float**): Registra la puntuación real calculada de SPD, EOD o DI.
- **fair:hasThreshold** (Dominio: **fair:FairnessContract** o Rango: **xsd:float**): Define el límite de tolerancia establecido en el contrato declarativo.
- **fair:isGatePassed** (Dominio: **fair:GateExecution** o Rango: **xsd:boolean**): Almacena el resultado lógico binario (true o false) de la evaluación de la compuerta.
- **fair:hasShapValue** (Dominio: **fair:ExplainabilityRecord** o Rango: **xsd:float**): Registra cuantitativamente la contribución de la característica financiera a la decisión.
- **prov:startedAtTime** (Dominio: **fair:GateExecution** o Rango: **xsd:dateTime**): Almacena la marca temporal exacta de la ejecución.

Al mapear estas relaciones y propiedades de datos, se demuestra de forma analítica que el diseño de la Ontología OWL de Fairness cumple estrictamente con el indicador, logrando tejer una red semántica robusta donde las trazas operativas de *Machine Learning* (**hasDvcHash**, **ModelVersion**), las evaluaciones de aseguramiento de calidad (**GateExecution**, **FairnessMetric**) y los requisitos legales (**ExplainabilityRecord** via SHAP, **ComplianceReport**) se unifican bajo un único modelo lógico auditable y de acceso declarativo en la Zona 4.

4.5. Discusión

4.5.1. Síntesis de los resultados principales

El desarrollo del **Objetivo Específico 2** ha permitido consolidar un modelo conceptual de diseño abstracto, matemático y semántico unificado para el aseguramiento ético del scoring crediticio, resolviendo las tres dimensiones de la problemática desde la fase de planificación de software. El primer resultado (R.E.2.1) materializa la topología de la solución bajo el **Modelo C4**, **segregando los flujos del pipeline MLOps** de integración continua local en cuatro Zonas operativas y localizando estratégicamente las compuertas de control.

El segundo resultado dota a estas compuertas de rigor cuantitativo al **formular matemáticamente los contratos de equidad** basados en el paradigma de diseño por contrato (DbC), aplicando aserciones probabilísticas específicas sobre el deudor, los transformadores de datos y el clasificador supervisado mediante métricas canónicas como SPD, EOD e Impacto Dispar.

Por último, el tercer resultado resuelve el vacío de gobernabilidad ética mediante el **modelado lógico de una Ontología OWL de Fairness de alta especificidad**, la cual estructurará de forma semántica el linaje de datos y la procedencia técnica requerida para auditorías regulatorias robustas.

4.5.2. Interpretación del significado de los resultados

Estos resultados implican una transformación radical en el ciclo de vida de la ingeniería de software basado en Machine Learning. En primer lugar, significan transitar de un enfoque tradicional de mitigación tardía y post-hoc a una estrategia de aseguramiento continuo y preventivo de la calidad ética (*Shift-Left Testing*). Al ubicar la validación en tiempo de compilación (CI/CD) de manera segmentada por Zonas, los ingenieros pueden aislar el sesgo composicional y diagnosticar con exactitud qué elemento específico (el lote de datos, un transformador por proxy o el entrenamiento) introdujo la distorsión ética.

En segundo lugar, la formulación matemática de los contratos utilizando los estándares de Hardt et al. (2016) y Bartlett et al. (2022) dota a la Fintech de una herramienta analítica objetiva para explotar la multiplicidad del modelo. Esto significa que el orquestador CI/CD no busca de forma ciega un modelo de máxima precisión teórica, sino que utiliza las aserciones para forzar iterativamente la selección de un clasificador que, encontrándose en la frontera de Pareto, ofrezca la máxima precisión posible respetando simultáneamente los umbrales de equidad y los límites de la regla de los cuatro quintos.

Finalmente, el modelado conceptual de la ontología OWL de trazabilidad significa que la Fintech adquiere la capacidad de cerrar la brecha de explicabilidad legal exigida por la circular de la CFPB (CFPB, 2023). Al interconectar semánticamente los datos de la solicitud de crédito con los valores locales SHAP y los logs de la ejecución de CI, la organización puede responder de forma declarativa e inmutable ante el rechazo de un cliente, demostrando ante reguladores que el proceso predictivo fue transparente y estuvo gobernado éticamente de extremo a extremo.

4.5.3. Contextualización con la revisión de la literatura

Los resultados de diseño obtenidos en esta investigación son plenamente consistentes con los avances y las metodologías analizadas en el Estado del Arte (Capítulo 3), pero introducen significativas mejoras y extensiones arquitectónicas frente a las soluciones previas de la industria:

- **Consistencia con el paradigma de Contratos de Equidad:** El uso de aserciones de software basadas en precondiciones y postcondiciones modulares para interrumpir flujos de compilación se alinea directamente con las metodologías seminales de Giang Nguyen (Nguyen, 2024; Nguyen et al., 2025). Sin embargo, mientras que la literatura de Nguyen se limita al espacio de entrenamiento aislado de AutoML en entornos de desarrollo, la arquitectura propuesta en esta tesis extiende el paradigma acoplándose a flujos MLOps de Nivel 2, incorporando una Zona de monitoreo en producción (Zona 3) y una capa semántica superior (Zona 4) para cerrar el ciclo de vida continuo.
- **Mitigación del Sesgo Composicional:** La inclusión de la QA Gate 2 en la Zona 1 para auditar transformadores y detectar de forma temprana la inyección de correlaciones por proxy responde de forma directa a la caracterización del sesgo composicional de Biswas y Rajan (Biswas & Rajan, 2021). Nuestra formulación amplía este enfoque al proponer la correlación condicional como métrica declarativa YAML de interrupción modular.
- **Estandarización de la Trazabilidad:** El diseño de la Ontología OWL y el uso de triples RDF se basan en el marco de gobernanza de datos y documentación ética de Russo et al. (2024) y Russo y Vidal (2025). Nuestra propuesta aporta valor incremental al especificar las clases lógicas de MLOps (como **fno:ExecutionRun** y **fno:QAGate**) y acoplar el modelado con valores de explicabilidad SHAP locales para dar cumplimiento explícito a las Adverse Action Notifications reguladas por la ECOA y la circular de la CFPB (CFPB, 2023).

4.5.4. Generalización de los resultados

Aunque la arquitectura y los contratos lógicos diseñados en este capítulo se han verticalizado sobre el dominio del scoring crediticio global, el diseño de la solución es inherentemente generalizable e interoperable. Debido a que las especificaciones de las QA Gates y las clases lógicas de la Ontología OWL de

Fairness se estructuraron de forma tecnológicamente agnóstica, estas pueden ser transferidas directamente a cualquier sistema de software inteligente basado en aprendizaje supervisado que realice tareas de clasificación binaria de alta dimensionalidad sobre datos estructurados en mercados regulados. Ejemplos de generalización sectorial incluyen:

- **Sistemas de Selección de Personal (Recursos Humanos):** Adaptando los atributos protegidos a variables de género o nacionalidad, y configurando la QA Gate 3 para evaluar el Impacto Dispar en la tasa de contratación de minorías.
- **Sistemas de Suscripción de Seguros (Insurtech):** Utilizando las aserciones de la QA Gate 2 para identificar si variables proxy como el código postal actúan como sustitutos discriminatorios de condiciones médicas preexistentes.
- **Flujos de Admisión Universitaria o Becas:** Forzando la paridad demográfica en las tasas de selección para garantizar representatividades balanceadas de colectivos desfavorecidos conforme a normativas de inclusión del Estado.

4.5.5. Limitaciones de los resultados

En cumplimiento estricto con las directrices de esta universidad y para anticiparnos a las evaluaciones del jurado, se declaran con total transparencia las limitaciones teóricas y de diseño de la propuesta de solución, acompañadas de sus respectivas justificaciones de ingeniería:

- **Restricción a Datos Estructurados y Tabulares:** Las formulaciones matemáticas de los Contratos de Equidad (SPD, EOD, DI) y el validador de esquemas de Pandera están especificados de forma exclusiva para matrices de datos tabulares estructurados. Esta arquitectura no abarca datos no estructurados de alta dimensionalidad como texto libre (procesamiento de lenguaje natural) o imágenes (visión computacional). Esta delimitación se justifica porque el scoring crediticio bancario y Fintech opera mayoritariamente sobre variables cuantitativas de comportamiento financiero y demográfico tabular.
- **Supuesto de Atributos Protegidos Autodeclarados:** Las postcondiciones de equidad de las QA Gates asumen de manera teórica que la variable demográfica sensible Z (como género o edad) se encuentra disponible y etiquetada en el lote de datos crudos para poder

calcular las aserciones. En la práctica financiera real, estas variables a menudo no son recolectadas explícitamente para evitar discriminación directa. Se justifica esta asunción porque la arquitectura está diseñada para operar como una plataforma de auditoría ética y simulación en entornos de validación controlados (*staging*), donde el acceso a datos demográficos históricos está autorizado bajo marcos de investigación y pruebas de impacto reguladas.

- **Consumo de Recursos Computacionales por Explicabilidad:** La inclusión de los valores SHAP de explicabilidad local en la postcondición de la Zona 2 añade una complejidad temporal significativa al pipeline de integración continua, dado que el cálculo de valores de Shapley mediante simulaciones en modelos no lineales es computacionalmente costoso. Esta limitación se justifica de forma técnica y legal porque la transparencia y la justificación del rechazo crediticio son mandatos obligatorios no negociables bajo la ECOA (CFPB, 2023); por consiguiente, el costo de cómputo en la compilación es marginal en comparación con los riesgos de multas de cumplimiento y las sanciones de mercado que la Fintech asumiría al desplegar un modelo indocumentado.

Capítulo 5: Implementación de la propuesta de solución

5.1. Introducción

El presente capítulo documenta la implementación del prototipo funcional de la arquitectura MLOps diseñada en el Capítulo 4, correspondiente al Objetivo Específico 3 (O3) del proyecto. Mientras que el capítulo anterior estableció el *qué* (la estructura de cuatro Zonas modelada con C4, la formulación matemática de los Contratos de Equidad y el esquema ontológico de trazabilidad), este capítulo aborda el *cómo*: la materialización de ese diseño en un sistema ejecutable, verificable y reproducible.

La implementación se organiza en torno a los tres resultados esperados del Objetivo 3. El resultado R.3.1 comprende la configuración de la infraestructura base: el versionado de datos mediante DVC y la automatización del pipeline de integración continua mediante GitHub Actions. El resultado R.3.2 corresponde a la programación e instrumentación de las compuertas de calidad (QA Gates) que materializan los Contratos de Equidad C1, C2 y C3 como pruebas automatizadas. Finalmente, el resultado R.3.3 aborda la integración del servicio de monitoreo y registro, que articula el seguimiento de experimentos con el almacenamiento semántico del linaje de ejecuciones.

Cada sección sigue una estructura uniforme de cuatro apartados. El primero describe el resultado alcanzado en términos de los artefactos producidos. El segundo detalla la metodología seguida y las condiciones necesarias para reproducir el resultado en otro entorno. El tercero aporta la verificación de existencia: la evidencia concreta y localizable de que el artefacto existe y opera. El cuarto presenta las mediciones obtenidas y valida el indicador definido para ese resultado esperado.

Conviene señalar una desviación deliberada respecto del orden nominal establecido en el cronograma del proyecto. El cronograma agrupa en R.3.1 la configuración de DVC y la de CI/CD, situando ambas antes de la programación de las QA Gates (R.3.2). Sin embargo, la ejecución real siguió la secuencia DVC → QA Gates → CI/CD, por una razón de dependencia técnica: un pipeline de integración continua requiere, para ser configurado y verificado, que existan previamente las pruebas que habrá de ejecutar. Configurar GitHub Actions sobre un repositorio sin lógica de validación produciría un workflow

vacío, imposible de validar contra un indicador. Esta reordenación no altera el alcance ni los entregables comprometidos: ambos resultados se completan dentro del mismo objetivo, y la trazabilidad entre tarea planificada y artefacto producido se mantiene íntegra.

El entorno de desarrollo utilizado fue una estación de trabajo local con sistema operativo Windows y Python 3.11, coherente con el requisito de diseño de que la arquitectura opere de forma desconectada de servicios en la nube. El caso de estudio empleado es un conjunto de datos de scoring crediticio proveniente de una fintech real, seleccionado tras un análisis comparativo de alternativas documentado en la sección correspondiente.

5.2. Configuración CI/CD y versionado de datos

5.2.1. Descripción del resultado alcanzado

Este resultado comprende dos componentes de infraestructura que sostienen la operación reproducible y automatizada del resto del sistema: el versionado de datos y la automatización del pipeline de integración continua.

5.2.2. Metodología de logro y reproducibilidad

5.2.3. Verificación de existencia

5.2.4. Mediciones y validación de indicador

5.3. Programación e instrumentación de las QA Gates

5.3.1. Descripción del resultado alcanzado

5.3.2. Metodología de logro y reproducibilidad

5.3.3. Verificación de existencia

5.3.4. Mediciones y validación de indicador

5.4. Integración de Servicio de Monitoreo y Registro

5.4.1. Descripción del resultado alcanzado

5.4.2. Metodología de logro y reproducibilidad

5.4.3. Verificación de existencia

5.4.4. Mediciones y validación de indicador

5.5. Discusión

5.5.1. Síntesis de resultados principales

5.5.2. Interpretación del significado de los resultados

5.5.3. Contextualización de la revisión de la literatura

5.5.4. Generalización de los resultados

5.5.5. Limitaciones de los resultados

Referencias bibliográficas

Petticrew, M., & Roberts, H. (2006). Systematic Reviews in the Social Sciences: A Practical Guide. Blackwell Publishing.

Amazon Web Services. (2022). Amazon SageMaker Model Monitor [Documento técnico]. AWS AI Team.

Ghai, B., Mishra, M., & Mueller, K. (2022). *Cascaded Debiasing: Studying the Cumulative Effect of Multiple Fairness-Enhancing Interventions*. *Proceedings of the 31st ACM International Conference on Information and Knowledge Management (CIKM '22)*, 1-11. <https://doi.org/10.1145/3511808.3557155>

Li, Y., et al. (2023). *Causality-Aided Trade-off Analysis*. [Manuscrito de investigación]. The Hong Kong University of Science and Technology.

Grafberger, S., Groth, P., Stoyanovich, J., & Schelter, S. (2022). *Data distribution debugging in machine learning pipelines*. *The VLDB Journal*, 31(5), 1103–1126.

Vasquez, J., Domeniconi, C., & Rangwala, H. (2023). *DispaRisk: Assessing Fairness Through Usable Information*. George Mason University; Universidad de Valparaíso.

Russo, M., Chudasama, Y., Purohit, D., Sawischa, S., & Vidal, M.-E. (2024). *Employing Hybrid AI Systems to Trace and Document Bias in ML Pipelines*. *IEEE Access*, 12, 96821-96847. <https://doi.org/10.1109/ACCESS.2024.3427388>

Biswas, S., & Rajan, H. (2021). *Fair Preprocessing: Towards Understanding Compositional Fairness of Data Transformers in Machine Learning Pipeline*. *Proceedings of the 29th ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE '21)*, 1-13. <https://doi.org/10.1145/3468264.3468536>

Reda, A., Taie, S. A., & Shaheen, M. E. (2025). *Hybrid MLOps framework for automated lifecycle management*. *Scientific Reports*, 15(1). <https://doi.org/10.1038/s41598-025-23600-z>

Kazmierczak, J., Salama, K., & Huerta, V. (2024). *MLOps: Canalizaciones de automatización y entrega continua en el aprendizaje automático*. Google Cloud Architecture Center. Recuperado de la documentación de Google Cloud.

Lin, Y. C., Mallia, D., Clark-Sevilla, A. O., Catto, A., Leshchenko, A., Haas, D. M., Wapner, R., Pe'er, I., Raja, A., & Salleb-Aouissi, A. (s.f.). *Preeclampsia*

Predictor with Machine Learning: A Comprehensive and Bias-Free Machine Learning Pipeline. Columbia University.

Schelter, S., Grafberger, S., Guha, S., Karlaš, B., & Zhang, C. (2023). *Proactively Screening Machine Learning Pipelines with ArgusEyes. Companion of the 2023 International Conference on Management of Data (SIGMOD-Companion '23).* <https://doi.org/10.1145/3555041.3589682>

Zhu, J., Xu, G., Lorenzi, F., Glavic, B., & Salimi, B. (2025). *Stress-Testing ML Pipelines with Adversarial Data Corruption [Reporte Técnico].*

Russo, M., & Vidal, M.-E. (2025). *Towards an Ontology-Driven Approach to Document Bias. Journal of Artificial Intelligence Research, 83, Artículo 38.* <https://doi.org/10.1613/jair.1.19388>

Avuthu, Y. R. (2021). *Trustworthy AI in Cloud MLOps: Ensuring Explainability, Fairness, and Security in AI-Driven Applications. Journal of Scientific and Engineering Research, 8(1), 246-255.*

Grafberger, S., Guha, S., Groth, P., & Schelter, S. (2023). *mlwhatif: What If You Could Stop Re-Implementing Your Machine Learning Pipeline Analyses Over and Over?. Proceedings of the VLDB Endowment, 16(12), 4002-4005.* <https://doi.org/10.14778/3611540.3611606>

IBM. (s.f.). *¿Qué es la gestión de riesgos de modelos? IBM Cloud Learn.* Recuperado de <https://www.ibm.com/>

Presidencia del Consejo de Ministros. (2025). *Decreto Supremo N° 115-2025-PCM: Decreto Supremo que aprueba el Reglamento de la Ley N° 31814, Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país. Diario Oficial El Peruano.*

Parlamento Europeo y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial y por el que se modifican los Reglamentos (CE) n.º 300/2008, (UE) n.º 167/2013, (UE) n.º 168/2013, (UE) 2018/858, (UE) 2018/1139 y (UE) 2019/2144 y las Directivas 2014/90/UE, (UE) 2016/797 y (UE) 2020/1828 (Reglamento de*

Inteligencia Artificial). *Diario Oficial de la Unión Europea*, L 2024/1689, 12 de julio de 2024.

Basel Committee on Banking Supervision. (2025). *Principles for the management of credit risk*. Bank for International Settlements. <https://www.bis.org/bcbs/publ/d591.htm>

Immaneni, J. (2020). *Building MLOps Pipelines in Fintech: Keeping Up with Continuous Machine Learning*. *International Journal of Artificial Intelligence, Data Science, and Machine Learning*, 1(2), 22–32. <https://doi.org/10.63282/30509262/IJAIDSML-VII2P103>

Byanjankar, A., Heikkilä, M., & Mezei, J. (2015). Predicting credit risk in peer-to-peer lending: A neural network approach. En *2015 IEEE Symposium Series on Computational Intelligence* (pp. 719–725). IEEE. <https://doi.org/10.1109/SSCI.2015.109>

MathWorks. (s. f.). *Credit Risk Modeling: Importance and Key Components*. MATLAB & Simulink Discovery. Recuperado el 18 de agosto de 2026, de <https://www.mathworks.com/discovery/credit-risk-modeling.html>

Demirgüç-Kunt, A., Klapper, L., Singer, D., & Ansar, S. (2022). *The Global Findex Database 2021: Financial Inclusion, Digital Payments, and Resilience in the Age of COVID-19*. World Bank. <https://doi.org/10.1596/978-1-4648-1897-4>

Menon, A. K., & Williamson, R. C. (2018). *The cost of fairness in binary classification*. En *Proceedings of the 1st Conference on Fairness, Accountability and Transparency (FAT* '18)*, 81, 107–118. PMLR.

Nguyen, G., Ahmed, S., Biswas, S., & Rajan, H. (2025). *Design by Fairness Contract for Machine Learning Pipeline*. En *Proceedings of the 47th International Conference on Software Engineering (ICSE 2025)*. IEEE.

Nguyen, G. (2024). *Fairness specification and repair for machine learning pipeline* (Tesis de doctorado). Iowa State University. Iowa State University Digital Repository. <https://doi.org/10.31274/etd-20240411-13>

Equal Credit Opportunity Act, 15 U.S.C. § 1691 et seq. (1974).
<https://www.govinfo.gov/link/uscode/15/1691>

Dhaenens, F. (2024). AI Governance in MLOps: Compliance, Fairness, and Transparency

Bartlett, R., Morse, A., Stanton, R., & Wallace, N. (2022). Consumer-lending discrimination in the FinTech era. *Journal of Financial Economics*, 143(1), 30–56. <https://doi.org/10.1016/j.jfineco.2021.05.047>

Consumer Financial Protection Bureau. (2023). *Consumer Financial Protection Circular 2023-03: Adverse action notification requirements and the proper use of the CFPB's sample forms provided in Regulation B.* CFPB. <https://www.consumerfinance.gov/compliance/circulars/circular-2023-03/>

Hardt, M., Price, E., & Srebro, N. (2016). Equality of opportunity in supervised learning. En *Advances in Neural Information Processing Systems* (pp. 3323–3331). Curran Associates, Inc.

Stoyanovich, J., Abiteboul, S., Howe, B., Jagadish, H. V., & Schelter, S. (2022). Responsible data management. *Communications of the ACM*, 65(6), 64–74. <https://doi.org/10.1145/3488716>

Kästner, C. (2021). *Data quality for building production ML systems.* Medium: Machine Learning in Production. <https://ckaestne.medium.com/data-quality-for-building-production-ml-systems-2e0cc7e6113f>

Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016, May 23). *Machine bias: There's software used across the country to predict future criminals. And it's biased against blacks.* ProPublica. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>

Adebayo, J., & Kagal, L. (2016). *Iterative orthogonal feature projection for diagnosing bias in black-box models*. arXiv preprint arXiv:1611.04967. <https://arxiv.org/abs/1611.04967>

Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A survey on bias and fairness in machine learning. *ACM Computing Surveys*, 54(6), 1–35. <https://doi.org/10.1145/3457607>

Black, E., & Fredrikson, M. (2021). Leave-one-out unfairness. En *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency* (pp. 285–295). Association for Computing Machinery. <https://doi.org/10.1145/3442188.3445914>

Ogrizović, M., Drašković, D., & Bojić, D. (2024). Quality assurance strategies for machine learning applications in big data analytics: an overview. *Journal of Big Data*, 11(1), 156. <https://doi.org/10.1186/s40537-024-01028-y>

International Organization for Standardization & International Electrotechnical Commission. (2023). *Information technology — Artificial intelligence — Management system* (ISO/IEC Standard No. 42001:2023). <https://www.iso.org/standard/81230.html>

Anexo A: Formulario de Extracción

 Formulario de Extracción

Anexo B: Plan de Proyecto

- **Justificación**

En la actualidad, los algoritmos de aprendizaje automático (*Machine Learning*) han transformado la toma de decisiones en sectores críticos como la atención médica, las finanzas y la justicia; sin embargo, han evidenciado el riesgo crítico de exacerbar y perpetuar sesgos sociales e históricos (Vasquez et al., 2023). A

medida que estos sistemas se implementan a gran escala, el sesgo algorítmico puede propagarse sistemáticamente a lo largo de las distintas etapas de la canalización de desarrollo, ocasionando impactos perjudiciales y discriminatorios sobre subgrupos de individuos, especialmente minorías, si no existen controles adecuados desde las etapas tempranas (Biswas & Rajan, 2021).

Frente a la necesidad de llevar estos modelos a producción, la industria ha adoptado el paradigma de MLOps (*Machine Learning Operations*). Si bien esta práctica automatiza el despliegue de software, los enfoques tradicionales adolecen de mecanismos de gobernanza efectivos y suelen evaluar la equidad (*fairness*) de forma estática al final del proceso, tratando al modelo como una "caja negra" (Dhaenens, 2024). Esta evaluación tardía es ineficiente porque ignora la naturaleza composicional del sesgo; es decir, la posibilidad de que la discriminación sea inyectada silenciosamente por operaciones intermedias, como el escalado o la imputación de datos durante la etapa de preprocesamiento (Biswas & Rajan, 2021).

Esta brecha técnica se ha convertido hoy en un estricto imperativo regulatorio. Marcos legales modernos, como el Reglamento (UE) 2024/1689 (Ley de IA de la Unión Europea), exigen que los sistemas de alto riesgo mitiguen los posibles sesgos y cuenten con un nivel adecuado de precisión, transparencia y supervisión humana para proteger los derechos fundamentales (Parlamento Europeo y Consejo de la Unión Europea, 2024). En el ámbito peruano, el Decreto Supremo N° 115-2025-PCM establece explícitamente que el desarrollo y uso de sistemas basados en IA deben garantizar la no discriminación y la rendición de cuentas, exigiendo a los implementadores mantener un registro actualizado y accesible sobre las fuentes de datos y la lógica del algoritmo para facilitar su auditoría (Presidencia del Consejo de Ministros, 2025).

En consecuencia, la presente investigación se justifica en la necesidad imperativa de diseñar e implementar una arquitectura MLOps que valide la equidad de manera continua a través de compuertas de calidad (*QA Gates*) preventivas. Al integrar controles modulares basados en "Contratos de Equidad", junto con mecanismos de trazabilidad semántica que emplean Grafos de Conocimiento para documentar el linaje de los modelos y las decisiones algorítmicas (Russo & Vidal, 2025), este proyecto aporta un valor práctico, técnico y metodológico invaluable. Su desarrollo permitirá a las organizaciones superar las deficiencias del monitoreo tradicional y cumplir con las normativas

vigentes, asegurando que la Inteligencia Artificial desplegada en la sociedad sea ética, auditable y segura por diseño.

- **Viabilidad**

La viabilidad del proyecto se sustenta en la disponibilidad de recursos técnicos, el acceso a fuentes de información estandarizadas y la capacidad metodológica y humana para desarrollar la arquitectura MLOps dentro del tiempo establecido.

Viabilidad técnica

Viabilidad técnica

El desarrollo y la automatización de la arquitectura propuesta no dependen de supercomputadoras inaccesibles, ya que el procesamiento principal se delegará a herramientas nativas de la nube y de código abierto. Se utilizarán plataformas de Integración y Entrega Continua (CI/CD) de acceso gratuito para repositorios académicos, como los *runners* de GitHub Actions, los cuales orquestrarán la canalización y ejecutarán las pruebas preventivas de *Pytest*. Asimismo, el modelado y almacenamiento de la trazabilidad semántica se desplegará mediante herramientas *open-source* como InterpretME y GraphDB, garantizando que no existan barreras de licencias comerciales restrictivas para completar el desarrollo.

Viabilidad respecto al acceso al conjunto de datos

A diferencia de investigaciones médicas o bancarias que dependen de información confidencial, este proyecto validará los "Contratos de Equidad" utilizando conjuntos de datos tabulares públicos que constituyen el estándar de evaluación en la literatura científica sobre equidad algorítmica y mitigación de sesgos. Se emplearán conjuntos de datos de una Fintech real. Estos datos ya se encuentran completamente anonimizados y son de libre acceso en repositorios de Machine Learning, lo que asegura la viabilidad ética e investigativa sin requerir la aprobación de comités externos.

Viabilidad metodológica y humana

La viabilidad metodológica y humana está garantizada. El tesista cuenta con la formación en ingeniería informática necesaria para instrumentar canalizaciones

de integración continua, programar pruebas de software y articular el ciclo de vida del aprendizaje automático. Además, este trabajo cuenta con la supervisión y validación técnica del Mg. Luis Vives, docente e investigador con amplia experiencia, lo que asegura el rigor metodológico durante las fases de diseño y validación experimental de la tesis.

Viabilidad institucional y alcance

Los productos entregables del proyecto son alcanzables dentro del cronograma académico debido a que la validación operativa está claramente delimitada. El sistema será validado mediante pruebas de estrés (*stress-testing*) inyectando derivas y sesgos sintéticos en un entorno de simulación controlado (*staging*), lo que permitirá comprobar la capacidad de interrupción de las compuertas de calidad sin la necesidad de desplegar e integrar la arquitectura en la infraestructura de una empresa o cliente real.

● Alcance

La presente investigación se enfoca en el diseño, implementación y validación experimental de una arquitectura MLOps de Nivel 2 orientada a la validación continua de equidad (*fairness*) en algoritmos de aprendizaje supervisado. El proyecto abarcará la construcción de una canalización integral que operará sobre conjuntos de datos tabulares.

El desarrollo del sistema incluye:

- La configuración de un entorno de Integración y Entrega Continua (CI/CD) automatizado.
- La programación e instrumentación de "Contratos de Equidad" modulares que actuarán como compuertas de calidad (*QA Gates*) con capacidad de interrupción durante la fase de preprocesamiento de datos.
- La integración de un módulo de trazabilidad semántica mediante Grafos de Conocimiento (empleando herramientas como InterpretME, RDFLib y GraphDB) para documentar el linaje de los datos, los hiperparámetros y las métricas de sesgo.
- La validación de la efectividad de la arquitectura mediante pruebas de estrés (*stress-testing*), las cuales consistirán en inyectar intencionalmente

deriva de datos (*data drift*) y sesgos sintéticos sobre modelos provenientes de pares académicos en un entorno de simulación (*staging*).

- **Limitaciones**

El desarrollo, la implementación y la validación del proyecto están sujetos a las siguientes restricciones tecnológicas y operativas:

- **Tipología de datos y algoritmos:** La arquitectura propuesta, así como las métricas matemáticas empleadas en los Contratos de Equidad, se diseñarán y validarán exclusivamente para modelos de aprendizaje supervisado aplicados a conjuntos de datos estructurados (tabulares). El alcance no cubre el procesamiento de datos no estructurados, como visión artificial, procesamiento de audio o lenguaje natural (texto libre).
- **Entorno de despliegue operativo:** Los resultados del estudio son de carácter experimental y académico. La evaluación de la arquitectura se realizará en un entorno de simulación controlado (*staging*) utilizando *datasets* públicos. El sistema no será implementado, integrado ni operado en la infraestructura de producción real de una entidad gubernamental o privada.
- **Restricciones de capacidad computacional:** La instrumentación de la trazabilidad semántica (Zona 4 de la arquitectura) y la generación iterativa de Grafos de Conocimiento exigen una carga significativa de procesamiento y consumo de memoria RAM. Esta exigencia de hardware podría limitar el volumen máximo de los conjuntos de datos que se podrán procesar simultáneamente durante las pruebas de estrés locales, acotando los escenarios de simulación a los recursos computacionales disponibles por el tesista.

- **Identificación de los riesgos del proyecto**

Durante la planificación del proyecto se identificaron los principales riesgos que podrían afectar su desarrollo, considerando aspectos técnicos, de gestión y de disponibilidad de recursos. En la siguiente tabla se describen los riesgos potenciales, sus síntomas, nivel de probabilidad, impacto y severidad, así como las estrategias de mitigación y contingencia propuestas para reducir sus efectos.

La severidad (S) se calcula como el producto entre la probabilidad (P) y el impacto (I). Los niveles se clasifican en una escala de Muy Bajo (1) a Muy Alto (5).

Descripción	Síntomas	Probabilidad (P)	Impacto (I)	Severidad (S)	Mitigación	Contingencia
Incompatibilidad de versiones entre bibliotecas de MLOps y Trazabilidad	Errores de ejecución en la canalización al integrar módulos como MLflow, AIF360 e InterpretME en un mismo flujo.	3	4	12	Uso de entornos virtuales e imágenes de contenedores Docker con versiones de bibliotecas estables y fijadas (<i>pinned requirements</i>).	Aislar temporalmente el componente defectuoso del pipeline CI/CD o buscar bibliotecas <i>open-source</i> equivalentes para la validación.
Sobrecarga computacional al generar el Grafo de Conocimiento	Mensajes de error por falta de memoria (RAM) o tiempos de ejecución excesivamente largos al transformar metadatos a formato RDF en GraphDB.	3	4	12	Limitar el volumen de los datos o la cantidad de hiperparámetros y <i>features</i> a trazar en el modelo conceptual.	Migrar la carga de generación semántica temporalmente a un entorno en la nube (ej. Google Colab) o simplificar la ontología de sesgos.
Falta de convergencia de modelos sesgados en las pruebas de estrés	Los modelos no logran entrenarse correctamente o las métricas de equidad son inconsistentes tras inyectar el sesgo sintético (<i>bias drift</i>).	2	4	8	Seleccionar conjuntos de datos estándar ampliamente validados en la literatura de equidad algorítmica (<i>Adult Income</i> , <i>COMPAS</i>).	Ajustar los niveles de inyección sintética de sesgos o utilizar cuatro algoritmos predictivos base menos complejos (ej. Regresión Logística).

Limitaciones en conocimientos técnicos sobre Web Semántica	Retrasos en el desarrollo de la Zona 4 de la arquitectura, errores al diseñar la ontología o fallos al formular consultas SPARQL.	3	3	9	Fortalecer la capacitación revisando la documentación oficial de InterpretME y RDFLib; mantener comunicación continua con el asesor.	Emplear consultas SPARQL genéricas predefinidas en la literatura para extraer únicamente el linaje de datos más elemental.
Retrasos en el cronograma de trabajo del proyecto	Atraso en entregables, acumulación de tareas de programación de las <i>QA Gates</i> o demoras en las revisiones con el asesor	3	3	9	Elaborar un cronograma semanal con hitos verificables y establecer reuniones planificadas con el asesor	Reajustar prioridades y simplificar experimentos no críticos para cumplir con la validación de la arquitectura central.

Tabla 10. Riesgos Identificados

- **Estructura de descomposición del trabajo (EDT)**

Para la planificación y ejecución ordenada del proyecto, se ha desarrollado una Estructura de Descomposición del Trabajo (EDT) que divide la investigación en paquetes de trabajo manejables. El primer nivel representa el proyecto en su totalidad, el segundo nivel corresponde a los cuatro objetivos específicos y el tercer nivel detalla los resultados esperados (entregables) de cada fase:




Figura 10: Estructura de descomposición del trabajo

● Lista de tareas

Tarea	Duración (días)	Esfuerzo (horas)	Costo (S/.)
1. Análisis del Estado del Arte y Brechas	20	40	2000
1.1. Ejecutar revisión sistemática y filtrado de estudios	13	26	1300
1.2. Elaborar matriz comparativa de automatización y trazabilidad	5	10	500
1.3. Redactar el informe de brechas tecnológicas	2	4	200
2. Diseño de la Arquitectura MLOps	30	60	3000
2.1. Elaborar el modelo C4 y definir el flujo del pipeline CI/CD	14	28	1400

2.2. Diseñar y formular matemáticamente los Contratos de Equidad	6	12	600
2.3. Modelar la ontología y esquema del Grafo de Conocimiento	10	20	1000
3. Desarrollo e Implementación	50	100	5000
3.1. Configurar CI/CD (GitHub Actions) y versionado de datos (DVC)	10	20	1000
3.2. Programar e instrumentar las QA Gates (Pytest, AIF360)	25	50	2500
3.3. Integrar InterpretME, MLflow y almacenamiento en GraphDB	15	30	1500
4. Validación y Evaluación del Sistema	25	50	2500
4.1. Configurar entorno <i>staging</i> e inyectar sesgos sintéticos	10	20	1000
4.2. Ejecutar validación comparativa y extraer métricas de equidad	10	20	1000
4.3. Extraer reportes (SPARQL) y redactar informe final de viabilidad	5	10	500
TOTAL ESTIMADO	125 días	250 horas	S/. 12500

Tabla 11: Lista de Tareas

- **Cronograma del proyecto**

Con base en la lista de tareas, se elaboró un cronograma de trabajo secuencial para los **109 días** de ejecución previstos (aproximadamente 16 semanas de dedicación asumiendo 2 horas diarias). Este cronograma detalla el flujo de actividades y sus dependencias, asegurando que la validación y evaluación solo se ejecuten cuando la arquitectura haya sido íntegramente desarrollada:

Cronograma_Detallado_20202117_SergioChumbimuni

● Lista de recursos

Para la correcta ejecución del proyecto se ha identificado el recurso humano, los equipos de cómputo y el *stack* tecnológico especializado (orientado al *Machine Learning* y a la Web Semántica) que se empleará durante todo el ciclo de desarrollo.

a) Personas involucradas:

- Tesista: Responsable del diseño, programación, implementación de la arquitectura MLOps, instrumentación de la trazabilidad y redacción del informe.
- Asesor: El Mg. Luis Vives Garnique, quien brinda supervisión metodológica y validación técnica en el despliegue de las integraciones de ingeniería de software.

b) Materiales requeridos:

- Internet: Esencial para orquestar la canalización en la nube (GitHub Actions), instalar contenedores y descargar los *datasets* públicos.
- Energía eléctrica: Para la operación continua del entorno de desarrollo.

c) Equipamiento:

- Laptop personal: Equipo de alto rendimiento capaz de ejecutar modelos de aprendizaje automático y virtualizar servicios, necesario para el prototipado inicial, procesamiento de datos y validación de las compuertas de calidad.

d) Herramientas requeridas (Software):

- Lenguaje de programación: Python.
- Desarrollo y automatización: Pandas y scikit-learn (preprocesamiento y entrenamiento), GitHub Actions (orquestador de CI/CD), DVC

(versionado de datos), MLflow (monitoreo y registro de modelos), y Pytest (evaluación de los Contratos de Equidad en tiempo de compilación).

- Equidad Algorítmica: AIF360 y Fairlearn para calcular disparidades estadísticas; y SHAP para la explicabilidad local de características.
- Trazabilidad Semántica: InterpretME (para generar el linaje semántico del pipeline), RDFLib (procesamiento de grafos en Python), GraphDB (base de datos orientada a grafos) y SPARQL (lenguaje de consultas estructuradas).

- **Costeo del Proyecto**

Se realizó una estimación económica del proyecto integrando el tiempo de dedicación del tesista (250 horas calculadas a una base de S/. 50.00 por hora), así como los costos proporcionales de servicios y equipamiento. Al emplearse una arquitectura fundamentada exclusivamente en herramientas de código abierto (*open-source*), los costos por licencias de software son nulos.

Ítem	Descripción	Unidad	Cantidad	Valor Unidad (S/.)	Monto Total (S/.)
0	Costo total del proyecto	---	---	---	14,725
1.	Estudiantes o tesisistas	---	---	---	12,500
1.1	Sergio Alonso Chumbimuni Bustamante	Horas	250	50	12,500
2.	Otros participantes	---	---	---	0
2.1	Asesor (Mg. Luis Vives Garnique)	---	---	---	0 (*)
3.	Servicios e infraestructura	---	---	---	600
3.1	Internet y electricidad (proporcional al tiempo)	Mes	4	150	600
4.	Bienes y equipos	---	---	---	625
4.1	Equipo de cómputo (costo referencial)	Horas	250	2.50	625
4.2	Licencias de Software (<i>Stack open-source</i>)	Unidad	1	0	0

Tabla 12: Costos del Proyecto

(*): Este costo operativo son asumidos por la universidad.